BỘ GIÁO DỤC VÀ ĐÀO TẠO

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ KỸ THUẬT HƯNG YÊN



BÀI TẬP LỚN

ỨNG DỤNG HỌC SÂU
TRONG VIỆC PHÁT HIỆN BẠO LỰC

NGÀNH: KHOA HỌC MÁY TÍNH

CHUYÊN NGÀNH: TRÍ TUỆ NHÂN TẠO VÀ KHOA HỌC DỮ LIỆU

SINH VIÊN: NGUYỄN MINH HIẾU

MÃ SINH VIÊN: 12423049

MÃ LỚP: 124231

GIẢNG VIÊN HƯỚNG DẪN: PGS. TS. NGUYỄN MINH TIẾN

HƯNG YÊN – 2026

NHẬN XÉT CỦA GIẢNG VIÊN HƯỚNG DẪN

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

Hưng Yên, ngày tháng năm 2026

(Ký và ghi rõ họ tên)

LỜI CAM ĐOAN

Em xin cam đoan đề tài "Ứng dụng học sâu trong việc phát hiện bạo lực xã hội" là kết quả nghiên cứu và thực hiện của cá nhân em dưới sự hướng dẫn của thầy Nguyễn Minh Tiến.

Toàn bộ nội dung, kết quả trình bày trong báo cáo cũng như chương trình xây dựng đều do em tự tìm hiểu, phát triển và thực hiện. Những tài liệu, dữ liệu và nội dung tham khảo từ các nguồn khác đều đã được trích dẫn và ghi rõ trong phần tài liệu tham khảo của báo cáo.

Em xin hoàn toàn chịu trách nhiệm trước Khoa và Nhà trường nếu có bất kỳ sự sao chép hoặc vi phạm nào liên quan đến nội dung cam đoan này.

Hưng Yên, ngày tháng năm 2026

Sinh viên

LỜI CẢM ƠN

Trước hết, em xin gửi lời cảm ơn chân thành đến thầy Nguyễn Minh Tiến đã tận tình hướng dẫn, giúp đỡ và góp ý cho em trong suốt quá trình thực hiện bài tập lớn "Ứng dụng học sâu trong việc phát hiện bạo lực xã hội". Những kiến thức và sự hướng dẫn của thầy đã giúp em hoàn thành bài tập lớn này.

Em xin cảm ơn các thầy cô trong Khoa Công nghệ Thông tin – Trường Đại học Sư phạm Kỹ thuật Hưng Yên đã tạo điều kiện thuận lợi trong quá trình học tập và cũng như thực hiện đồ án.

Do kiến thức và kinh nghiệm thực tế còn hạn chế nên đồ án khó tránh khỏi những thiếu sót. Em rất mong nhận được sự góp ý từ thầy cô để bài làm được hoàn thiện hơn.

Hưng Yên, ngày tháng năm 2026

Sinh viên thực hiện

Nguyễn Minh Hiếu

LỜI TUYÊN BỐ SỬ DỤNG AI

Tôi là Nguyễn Minh Hiếu,người thực hiện bài tập lớn với đề tài "Ứng dụng học sâu trong phát hiện bạo lực". Tôi xin công khai việc sử dụng công cụ trí tuệ nhân tạo (AI) trong quá trình thực hiện bài tập lớn như sau:

STT	Nội dung khai báo	Yes	No
1	Sử dụng AI hỗ trợ viết báo cáo	X	
2	Sử dụng AI hỗ trợ sinh các biểu đồ	X	
3	Sử dụng AI hỗ trợ sinh giao diện	X	
4	Sử dụng AI hỗ trợ sinh test cases		X

Tỷ lệ sử dụng AI ước tính trong quá trình thực hiện bài tập lớn: 80%.

AI được sử dụng để thu thập các thông tin, gợi ý mã nguồn tạo biểu đồ, hỗ trợ xây dựng giao diện demo và giải thích một số vấn đề kỹ thuật. Các nội dung do AI đề xuất đã được đối chiếu với dữ liệu, mã nguồn và kết quả thực nghiệm của đề tài trước khi đưa vào báo cáo.

Tôi chịu trách nhiệm về tính chính xác của số liệu, kết quả thực nghiệm, nội dung trình bày và các tài liệu tham khảo được sử dụng. Việc sử dụng AI không thay thế trách nhiệm của tôi trong việc hiểu, kiểm tra và giải thích các phương pháp đã áp dụng.

Tôi cam kết khai báo trung thực việc sử dụng AI; không sử dụng AI để tạo ra số liệu hoặc kết quả thực nghiệm không có thật.

Hưng Yên, ngày tháng 10 năm 2026

Sinh viên thực hiện

(Ký và ghi rõ họ tên)

MỤC LỤC

NHẬN XÉT CỦA GIẢNG VIÊN HƯỚNG DẪN 1
LỜI CAM ĐOAN 2
LỜI CẢM ƠN 3
LỜI TUYÊN BỐ SỬ DỤNG AI 4
DANH MỤC CÁC KÝ TỰ, CÁC TỪ VIẾT TẮT 8
DANH MỤC BẢNG 10
DANH MỤC CÁC HÌNH VẼ 11
MỞ ĐẦU 12
CHƯƠNG 1: TỔNG QUAN BÀI TOÁN PHÁT HIỆN HÀNH VI BẠO LỰC 19
1.1. Giới thiệu bài toán phát hiện hành vi bạo lực 19
1.2. Ứng dụng bài toán 20
1.3. Khó khăn và thách thức 22
1.4. Kết luận chương 23
CHƯƠNG 2: TÌM HIỂU CÁC KỸ THUẬT HỌC SÂU 24
2.1. YOLOv8 24
2.1.1. Kiến trúc 24
2.1.2. Hàm mất mát 24
2.1.3. Điểm cải tiến so với YOLOv5 25
2.2. EfficientDet-D0 26
2.2.1. Kiến trúc 26
2.2.2. Hàm mất mát 27
2.2.3. Điểm cải tiến so với FPN và NAS-FPN 27
2.3. EfficientNet-B0 27
2.3.1. Kiến trúc 27
2.3.2. Điểm cải tiến so với các mạng trước 28
2.3.3. Vai trò và cách huấn luyện 28
2.4. MobileNetV3-Large 29
2.4.1. Kiến trúc 29
2.4.2. Điểm cải tiến so với MobileNetV1 và MobileNetV2 29

2.4.3. Vai trò và so sánh với EfficientNet-B0 29
2.5. Các độ đo đánh giá 30
2.5.1. Độ đo phân loại 30
2.5.2. Độ đo phát hiện đối tượng 31
CHƯƠNG 3: XÂY DỰNG MÔ HÌNH PHÁT HIỆN BẠO LỰC XÃ HỘI 32
3.1. Thu thập dữ liệu, khảo sát và tiền xử lý 32
3.1.1. Giới thiệu bộ dữ liệu 32
3.1.2. Phân tích khám phá dữ liệu (EDA) 32
3.1.3. Độ phân giải, chất lượng dữ liệu và rò rỉ 35
3.1.4. Tiền xử lý và chuẩn bị dữ liệu 36
3.2. Xây dựng mô hình học sâu 37
3.2.1. Kiến trúc tổng quát của hệ thống 37
3.2.2. Giai đoạn 1 - Phát hiện đối tượng với YOLOv8n và EfficientDet-D0 37
3.2.3. Giai đoạn 2 - Phân loại với MobileNetV3-Large và EfficientNet-B0 38
3.2.4. Hai cấu hình pipeline hai giai đoạn 39
3.2.5. Quy trình huấn luyện và đánh giá 39
CHƯƠNG 4: KẾT QUẢ THỰC NGHIỆM MÔ HÌNH PHÁT HIỆN HÀNH VI BẠO LỰC 40
4.1 Môi trường và thiết lập thực nghiệm 40
4.1.1 Môi trường thực nghiệm 40
4.1.2 Dữ liệu và giao thức đánh giá 40
4.2 Kết quả phát hiện trực tiếp bằng mô hình một giai đoạn 42
4.2.1 Kết quả định vị và nhận diện đối tượng 42
4.2.2 Kết quả phân loại ở mức ảnh 43
4.3 Kết quả phát hiện người kết hợp phân loại hành vi 43
4.3.1 Đánh giá riêng hai bộ phân loại 43
4.3.2 Kết quả pipeline hoàn chỉnh 45
4.4 So sánh và phân tích kết quả 46
4.4.1 So sánh tổng thể trên cùng tập test 46
4.2.2 Ma trận nhầm lẫn và hai loại lỗi 46

4.4.3 Thời gian xử lý và giới hạn phép đo.....48
4.5 Hạn chế thực nghiệm và hướng cải thiện.....48
KẾT LUẬN.....50
TÀI LIỆU THAM KHẢO.....51

DANH MỤC CÁC KÝ TỰ, CÁC TỪ VIẾT TẮT

STT	Từ viết tắt	Dạng đầy đủ	Nghĩa
1	AI	Artificial Intelligence	Trí tuệ nhân tạo
2	AP	Average Precision	Độ chính xác trung bình
3	BCE	Binary Cross-Entropy	Hàm mất mát độ tự do chéo nhị phân
4	BiFPN	Bidirectional FeaturePyramid Network	Mạng kim tự tháp đặc trưng hai chiều
5	CIoU	Complete Intersection over Union	Chỉ số kiểm soát tỉ lệ khung hình và khoảng cách tâm giữa các hộp
6	CNN	Convolutional Neural Network	Mạng nơ-ron tích chập
7	COCO	Common Objects in Context	Bộ dữ liệu chuẩn đánh giá bài toán phát hiện đối tượng
8	DFL	Distribution Focal Loss	Hàm mất mát phân phối tiêu điểm
9	EDA	Exploratory Data Analysis	Phân tích khám phá dữ liệu
10	EMA	Exponential Moving Average	Trung bình động lũy thừa
11	FLOPs/MAdds	Floating Point Operations / Multiply-Accumulates	Số phép tính số thực phẩy động / số phép nhân-cộng
12	FN	False Negative	Âm tính giả
13	FP	False Positive	Dương tính giả

14	FPN	Feature Pyramid Network	Mạng kim tự tháp đặc trưng
15	IoU	Intersection over Union	Tỷ lệ diện tích giao trên diện tích hợp giữa hai hộp
16	LSTM	Long Short-Term Memory	Mạng bộ nhớ ngắn-dài
17	mAP	Mean Average Precision	Độ chính xác trung bình trung bình
18	NAS	Neural Architecture Search	Tìm kiếm kiến trúc mạng nơ-ron tự động
19	PAN/PANet	Path Aggregation Network	Mạng tổng hợp đường dẫn
20	P&R	Precision & Recall	Độ chính xác và độ gợi nhớ
21	RNN	Recurrent Neural Network	Mạng nơ-ron hồi tiếp
22	SE	Squeeze-and-Excitation	Mô-đun tái trọng số các kênh đặc trưng
23	SGD	Stochastic Gradient Descent	Phương pháp tối ưu hóa hạ độ dốc ngẫu nhiên
24	TN	True Negative	Âm tính đúng
25	TP	True Positive	Dương tính đúng
26	YOLO	You Only Look Once	Họ mô hình phát hện đối tượng thời gian thực
27	3D-CNN	3-Dimensional Convolutional Neural Network	Mạng nơ-ron tích chập 3 chiều

DANH MỤC BẢNG

Bảng 2. 1 Những điểm mới của YOLOv8 so với YOLOv5 25

Bảng 2. 2 So sánh hai mô hình phân loại Stage 2 30

Bảng 3. 1 Quy mô bộ dữ liệu theo từng tập 32

Bảng 3. 2 Thống kê phân bố lớp ở mức ảnh 33

Bảng 3. 3 Một số đặc trưng hình học của bounding box 34

Bảng 3. 4 Thống kê độ phân giải và chất lượng ảnh 35

Bảng 3. 5 Cấu hình huấn luyện bộ phân loại 38

Bảng 3. 6 Thiết lập dùng chung cho hai pipeline YOLOv8n + classifier 39

Bảng 4. 1 Môi trường và cấu hình đầu vào 40

Bảng 4. 2 Ngưỡng được chọn và kết quả trên validation 41

Bảng 4. 3 Kết quả detector trên tập test 42

Bảng 4. 4 Chỉ số detector theo lớp trên tập test 42

Bảng 4. 5 Kết quả mức ảnh của hai detector trên 748 ảnh test 43

Bảng 4. 6 Kết quả đánh giá riêng classifier 43

Bảng 4. 7 Kết quả mức ảnh của hai pipeline trên tập test 45

Bảng 4. 8 So sánh bốn phương án ở mức ảnh 46

Bảng 4. 9 Số lỗi và khả năng nhận diện NonViolence 46

Bảng 4. 10 Thời gian chạy pipeline được lưu trong tệp summary 48

DANH MỤC CÁC HÌNH VẼ

Hình 1. 1 Thống kê tình hình tội phạm về trật tự xã hội qua các năm. 12

Hình 1. 2 Hệ thống camera giám sát tại khu vực công cộng. 13

Hình 1. 3 Ứng dụng học sâu trong phân tích và nhận dạng hành vi từ video 14

Hình 1. 4 Không bạo lực và bạo lực 19

Hình 1. 5 Quy trình tổng quát của bài toán phát hiện hành vi bạo lực 20

Hình 1. 6 Một số môi trường ứng dụng hệ thống phát hiện hành vi bạo lực 21

Hình 2. 2 Kiến trúc tổng quát của YOLOv8 24

Hình 2. 3 Kiến trúc EfficientDet-D0 26

Hình 2. 4 Khối MBConv kèm Squeeze-and-Excitation (dùng trong EfficientNet và MobileNetV3) 28

Hình 3. 1 Phân bố số bounding box theo lớp và theo tập dữ liệu 33

Hình 3. 2 Phân bố số ảnh theo nhãn mức ảnh 34

Hình 3. 3 Phân bố độ sáng, tương phản và độ nét theo tập dữ liệu 35

Hình 3. 4 Heatmap vị trí tâm bounding box theo lớp 36

Hình 3. 5 Kiến trúc tổng quát của pipeline phát hiện bạo lực hai giai đoạn 37

Hình 4. 1 F1 trên validation theo ngưỡng quyết định Violence 41

Hình 4. 2 Đường loss và accuracy của MobileNetV3-Large 44

Hình 4. 3 Đường loss và accuracy của EfficientNet-B0 44

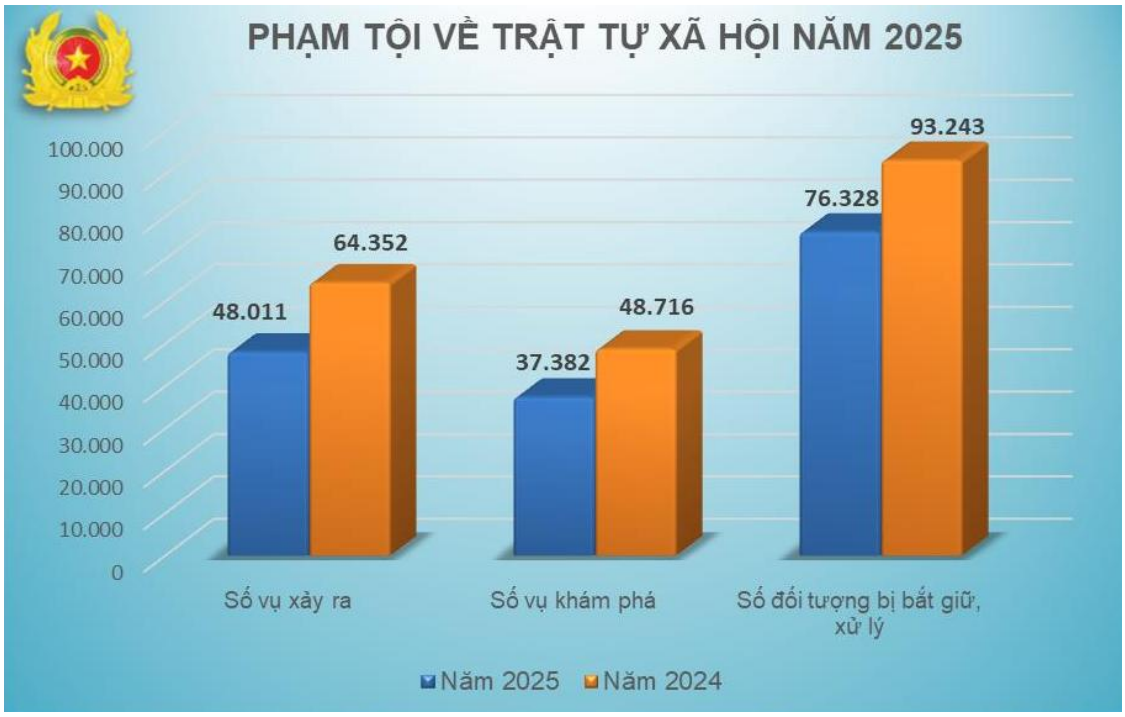
Hình 4. 4 Ma trận nhầm lẫn mức ảnh của bốn phương án 47

MỞ ĐẦU

Lý do chọn đề tài

Trong bối cảnh đô thị hóa diễn ra nhanh chóng, các hành vi bạo lực tại nơi công cộng như xô xát đường phố, gây rối trật tự công cộng và ẩu đả phát sinh từ các mâu thuẫn trong sinh hoạt, giao thông có thể gây ảnh hưởng nghiêm trọng đến sức khỏe, tính mạng và tài sản của người dân. Đặc biệt, những sự việc mang tính bộc phát thường diễn ra trong thời gian ngắn, có khả năng leo thang nhanh chóng và gây ra hậu quả khó lường. Điều này đặt ra yêu cầu cấp thiết về việc nâng cao hiệu quả giám sát, phát hiện sớm và hỗ trợ xử lý các hành vi bạo lực tại những khu vực công cộng.

Theo báo cáo phạm tội về trật tự xã hội năm 2025 của Bộ Công An [1] năm 2025 toàn quốc xảy ra 48.011 vụ; khám phá 37.382 vụ; bắt giữ, xử lý 76.328 đối tượng; tỷ lệ khám phá đạt 77,86%; triệt phá 39 băng, nhóm. So với năm 2024, giảm 16.341 vụ (-25,39%), số vụ khám phá giảm 11.334 vụ (-23,27%), số đối tượng bị bắt giữ, xử lý giảm 16.915 đối tượng (-18,14%); tỷ lệ khám phá tăng 2,16%; giảm 30 băng, nhóm bị triệt phá (-43,48%). Đây là các vụ việc được báo cáo và thường có mức độ lớn liên quan đến các băng nhóm chưa tổng hợp được các vụ việc nhỏ có ảnh hưởng để nhưng cá nhân



Hình 1. 1 Thống kê tình hình tội phạm về trật tự xã hội qua các năm.

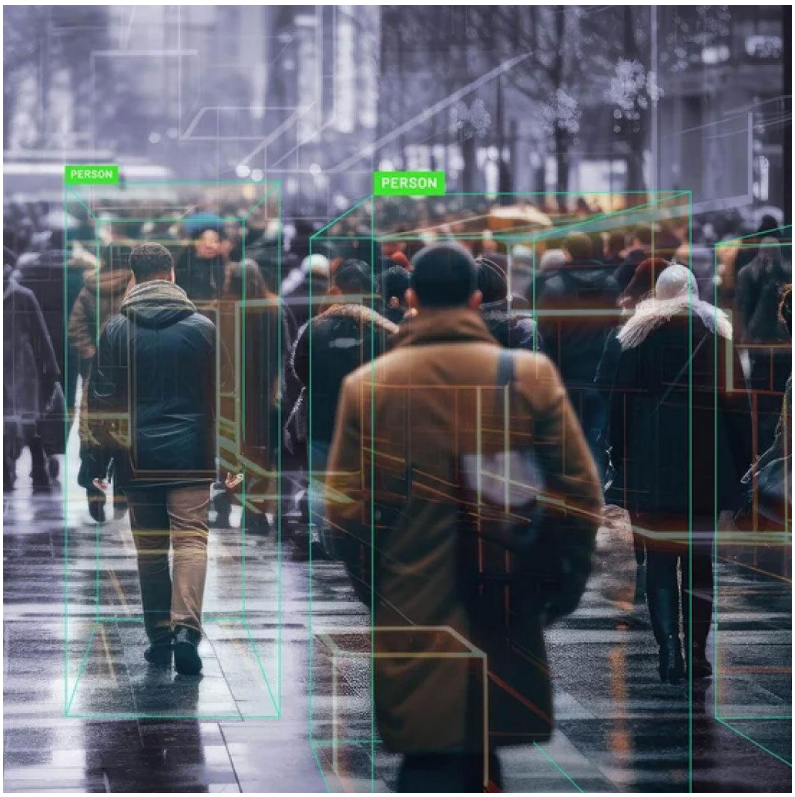
Hiện nay, hệ thống camera giám sát đã được triển khai rộng rãi tại các đô thị, tuyến đường giao thông, cơ sở kinh doanh và nhiều khu vực công cộng nhằm phục vụ công tác quản lý và bảo đảm an ninh. Tuy nhiên, phần lớn hệ thống camera truyền thống vẫn hoạt động theo cơ chế giám sát thụ động (Passive Monitoring), trong đó việc phát hiện và đánh giá các sự cố chủ yếu phụ thuộc vào khả năng quan sát của nhân viên trực giám sát. Khi phải theo dõi đồng thời nhiều luồng video trong thời gian dài, con người dễ gặp phải tình trạng giảm tập trung, mệt mỏi và bỏ sót những sự kiện bất thường. Do đó, camera giám sát trong nhiều trường hợp vẫn chủ yếu được sử dụng để xem lại hình ảnh, phục vụ công tác xác minh và điều tra sau khi sự việc đã xảy ra, thay vì chủ động phát hiện và cảnh báo nguy cơ ngay từ đầu.



Hình 1. 2 Hệ thống camera giám sát tại khu vực công cộng.

Trước những hạn chế của phương pháp giám sát truyền thống, sự phát triển của Trí tuệ nhân tạo (Artificial Intelligence – AI), đặc biệt là Thị giác máy tính (Computer Vision) và Học sâu (Deep Learning), đã mở ra nhiều hướng tiếp cận mới trong việc tự động phân tích dữ liệu hình ảnh và video. Thông qua các mô hình học sâu, máy tính có thể học và trích xuất những đặc trưng phức tạp từ dữ liệu hình ảnh, nhận diện đối tượng và phân tích các chuyển động diễn ra theo thời gian. Những khả năng này tạo cơ sở để phát triển các hệ thống có thể tự động nhận biết các hành vi bất thường, trong đó có hành vi bạo lực, từ dữ liệu video giám sát.

Trong lĩnh vực Thị giác máy tính, các mô hình mạng nơ-ron tích chập (Convolutional Neural Network – CNN) được sử dụng rộng rãi để trích xuất đặc trưng không gian từ hình ảnh. Bên cạnh đó, các kiến trúc như mạng nơ-ron hồi tiếp (Recurrent Neural Network – RNN), Long Short-Term Memory (LSTM) và mạng tích chập ba chiều (3D-CNN) có khả năng khai thác thông tin theo thời gian và đặc điểm chuyển động trong video. Ngoài ra, các mô hình phát hiện đối tượng như YOLO có thể được ứng dụng để xác định vị trí và theo dõi con người trong từng khung hình, hỗ trợ quá trình phân tích hành vi. Việc kết hợp các phương pháp phù hợp có thể giúp xây dựng hệ thống phát hiện hành vi bạo lực tự động, giảm sự phụ thuộc vào quá trình giám sát thủ công và hỗ trợ đưa ra cảnh báo khi xuất hiện những dấu hiệu đáng ngờ.



Hình 1. 3 Ứng dụng học sâu trong phân tích và nhận dạng hành vi từ video

Mặc dù vậy, phát hiện hành vi bạo lực từ video vẫn là một bài toán có nhiều thách thức về mặt kỹ thuật. Hệ thống không chỉ cần nhận diện được sự xuất hiện của con người mà còn phải phân tích mối quan hệ giữa các đối tượng, đặc điểm chuyển động và diễn biến của hành động theo thời gian. Một số hoạt động thông thường như vui đùa, chơi thể thao hoặc tương tác mạnh giữa nhiều người có thể có đặc điểm hình ảnh tương

tự hành vi bạo lực, dẫn đến nguy cơ phân loại nhầm. Bên cạnh đó, các yếu tố như góc quay camera, điều kiện ánh sáng, hiện tượng che khuất, chất lượng video và tốc độ xử lý cũng ảnh hưởng đáng kể đến hiệu quả hoạt động của mô hình.

Xuất phát từ nhu cầu ứng dụng trí tuệ nhân tạo vào công tác giám sát an ninh cũng như những thách thức trong bài toán nhận dạng hành vi từ video, đề tài "Ứng dụng học sâu trong phát hiện hành vi bạo lực" được lựa chọn nhằm nghiên cứu và áp dụng các kỹ thuật học sâu vào việc phân tích dữ liệu video, nhận dạng hành vi bạo lực và hỗ trợ phát hiện sự cố. Thông qua quá trình nghiên cứu, xây dựng và đánh giá mô hình, đề tài hướng đến việc tìm hiểu khả năng ứng dụng các phương pháp học sâu trong thực tế, đồng thời củng cố kiến thức về xử lý dữ liệu video, Thị giác máy tính và trí tuệ nhân tạo.

Mục tiêu của đề tài

Mục tiêu tổng quát của đề tài là nghiên cứu và ứng dụng các kỹ thuật học sâu để xây dựng mô hình có khả năng phát hiện hành vi bạo lực từ dữ liệu video. Hệ thống hướng đến việc tự động phân tích các khung hình và đặc điểm chuyển động của đối tượng, từ đó phân loại video hoặc đoạn video thành các nhóm hành vi phù hợp, chẳng hạn như bạo lực và không bạo lực. Kết quả nhận dạng có thể được sử dụng để hỗ trợ công tác giám sát, phát hiện sự cố và cảnh báo trong các môi trường có lắp đặt camera.

Các mục tiêu cụ thể của đề tài bao gồm:

Nghiên cứu tổng quan về bài toán phát hiện hành vi bạo lực từ video, các phương pháp nhận dạng hành động và những ứng dụng của học sâu trong lĩnh vực Thị giác máy tính.

Tìm hiểu nguyên lý hoạt động của các kiến trúc học sâu có liên quan như CNN, RNN, LSTM, 3D-CNN và các mô hình phát hiện đối tượng.

Tìm hiểu, thu thập và xử lý bộ dữ liệu video phục vụ cho bài toán phát hiện hành vi bạo lực, bao gồm các bước chuẩn hóa, trích xuất khung hình và xây dựng nhãn dữ liệu.

Xây dựng và huấn luyện mô hình học sâu nhằm nhận dạng hành vi bạo lực và hành vi không bạo lực từ dữ liệu video.

Thực hiện đánh giá mô hình thông qua các chỉ số phù hợp như Accuracy, Precision, Recall, F1-score và ma trận nhầm lẫn.

Xây dựng chương trình thử nghiệm cho phép đưa video đầu vào, phân tích nội dung và hiển thị kết quả nhận dạng hành vi.

Phân tích những ưu điểm, hạn chế của mô hình và đề xuất các hướng cải thiện nhằm nâng cao độ chính xác, tốc độ xử lý và khả năng ứng dụng trong thực tế.

Giới hạn và phạm vi nghiên cứu

Đề tài tập trung nghiên cứu việc ứng dụng các kỹ thuật học sâu trong bài toán phát hiện hành vi bạo lực từ dữ liệu video. Phạm vi nghiên cứu chủ yếu hướng đến việc nhận dạng hành vi ở mức tổng thể của một đoạn video hoặc chuỗi khung hình, phân biệt giữa các tình huống có dấu hiệu bạo lực và các hoạt động thông thường.

Về dữ liệu, đề tài sử dụng các bộ dữ liệu video phù hợp với bài toán nhận dạng hành vi bạo lực, được thu thập từ nguồn công khai hoặc các tập dữ liệu phục vụ nghiên cứu. Dữ liệu được xử lý và phân chia thành các tập huấn luyện, kiểm định và kiểm tra nhằm phục vụ quá trình xây dựng, tối ưu và đánh giá mô hình. Quy mô dữ liệu và các bộ dữ liệu cụ thể sẽ được xác định theo nguồn dữ liệu thực tế được sử dụng trong quá trình triển khai.

Về phương pháp, đề tài tập trung vào việc nghiên cứu các mô hình học sâu có khả năng trích xuất đặc trưng không gian và thời gian từ video. Các mô hình và kiến trúc được lựa chọn để thực nghiệm sẽ phụ thuộc vào đặc điểm dữ liệu, tài nguyên phần cứng và mục tiêu đánh giá của đề tài.

Về chức năng, hệ thống thử nghiệm tập trung vào việc tiếp nhận video đầu vào, tiền xử lý dữ liệu, thực hiện nhận dạng hành vi và hiển thị kết quả dự đoán. Các chức năng nâng cao như theo dõi nhiều đối tượng trong môi trường phức tạp, xác định chính xác từng hành động riêng lẻ, nhận diện danh tính, dự đoán nguy cơ bạo lực trước khi xảy ra hoặc tích hợp trên hạ tầng camera quy mô lớn không thuộc phạm vi bắt buộc của nghiên cứu cơ bản này.

Đề tài được thực hiện với mục đích nghiên cứu và thử nghiệm, do đó kết quả của mô hình cần được đánh giá trong phạm vi dữ liệu và điều kiện thực nghiệm cụ thể. Hệ

thống không thay thế hoàn toàn vai trò đánh giá và xử lý tình huống của con người trong công tác bảo đảm an ninh.

Nội dung thực hiện

Để đạt được các mục tiêu đã đề ra, đề tài được triển khai theo các nội dung chính sau:

Trước hết, tiến hành nghiên cứu các tài liệu, công trình khoa học và kiến thức chuyên ngành liên quan đến trí tuệ nhân tạo, học sâu, Thị giác máy tính và nhận dạng hành động từ video. Trên cơ sở đó, tìm hiểu đặc điểm của bài toán phát hiện hành vi bạo lực, các phương pháp tiếp cận phổ biến và những khó khăn cần giải quyết.

Tiếp theo, tiến hành tìm hiểu và thu thập dữ liệu video phục vụ cho quá trình huấn luyện và đánh giá mô hình. Dữ liệu sau khi thu thập sẽ được kiểm tra, phân tích và tiền xử lý nhằm loại bỏ những dữ liệu không phù hợp, chuẩn hóa định dạng video, trích xuất khung hình hoặc chuỗi khung hình và tổ chức dữ liệu theo các nhãn hành vi tương ứng.

Sau khi hoàn thành quá trình chuẩn bị dữ liệu, tiến hành nghiên cứu và xây dựng kiến trúc mô hình học sâu phù hợp với bài toán. Các mô hình được lựa chọn sẽ được huấn luyện trên tập dữ liệu đã chuẩn bị, đồng thời điều chỉnh các tham số cần thiết nhằm cải thiện khả năng nhận dạng và hạn chế hiện tượng quá khớp.

Tiếp theo, thực hiện các thí nghiệm để đánh giá hiệu quả của mô hình trên dữ liệu kiểm định và dữ liệu kiểm tra. Các kết quả được phân tích thông qua những chỉ số đánh giá, biểu đồ huấn luyện và ma trận nhầm lẫn để xác định khả năng nhận dạng đúng, mức độ bỏ sót và tỷ lệ dự đoán sai của mô hình.

Cuối cùng, xây dựng chương trình thử nghiệm nhằm đưa mô hình vào quá trình phân tích video thực tế ở quy mô phù hợp. Kết quả nhận dạng được hiển thị trực quan, hỗ trợ người dùng theo dõi các đoạn video được dự đoán có hành vi bạo lực. Trên cơ sở kết quả thực nghiệm, tiến hành nhận xét, đánh giá các hạn chế và đề xuất hướng phát triển cho hệ thống.

Phương pháp tiếp cận

Đề tài sử dụng kết hợp phương pháp nghiên cứu lý thuyết và phương pháp thực nghiệm để giải quyết bài toán phát hiện hành vi bạo lực từ video.

Phương pháp nghiên cứu lý thuyết được sử dụng nhằm tìm hiểu các kiến thức nền tảng về học sâu, mạng nơ-ron tích chập, các mô hình học tập theo chuỗi thời gian và các kỹ thuật nhận dạng hành động. Quá trình nghiên cứu tập trung vào nguyên lý hoạt động, cấu trúc, ưu điểm, hạn chế và khả năng ứng dụng của từng phương pháp trong việc phân tích dữ liệu video.

Phương pháp thực nghiệm được áp dụng trong quá trình xây dựng và đánh giá mô hình. Dữ liệu video được tiền xử lý và đưa vào mô hình để thực hiện quá trình huấn luyện, kiểm định và dự đoán. Các tham số huấn luyện được điều chỉnh phù hợp với tài nguyên tính toán và đặc điểm dữ liệu. Kết quả của các lần thực nghiệm được ghi nhận, phân tích và so sánh thông qua các chỉ số đánh giá nhằm xác định hiệu quả của phương pháp được triển khai.

Bên cạnh đó, phương pháp phân tích và đánh giá kết quả được sử dụng để làm rõ khả năng nhận dạng của mô hình trong các tình huống khác nhau, đặc biệt là những trường hợp dễ nhầm lẫn giữa hành vi bạo lực và hoạt động thông thường. Thông qua quá trình này, đề tài xác định những hạn chế còn tồn tại và đề xuất các giải pháp cải thiện mô hình.

CHƯƠNG 1: TỔNG QUAN BÀI TOÁN PHÁT HIỆN HÀNH VI BẠO LỰC

1.1. Giới thiệu bài toán phát hiện hành vi bạo lực

Phát hiện hành vi bạo lực (Violence Detection) là một bài toán thuộc lĩnh vực Thị giác máy tính và trí tuệ nhân tạo, có mục tiêu xác định sự xuất hiện của các hành vi bạo lực trong hình ảnh hoặc video. Bài toán này tập trung vào việc phân tích đặc điểm hình ảnh, chuyển động và sự tương tác giữa các đối tượng để phân biệt hành vi bạo lực với những hoạt động thông thường.

Khác với bài toán nhận dạng đối tượng chỉ tập trung xác định sự xuất hiện và vị trí của các đối tượng trong hình ảnh, phát hiện hành vi bạo lực đòi hỏi hệ thống phải xem xét cả diễn biến của hành động theo thời gian. Ví dụ, trong một đoạn video có hai người đang tương tác với nhau, chỉ dựa vào sự xuất hiện của hai đối tượng sẽ không đủ để xác định liệu họ đang trò chuyện, vui đùa hay xảy ra xô xát. Vì vậy, việc phân tích chuỗi khung hình và đặc điểm chuyển động đóng vai trò quan trọng trong quá trình nhận dạng hành vi.



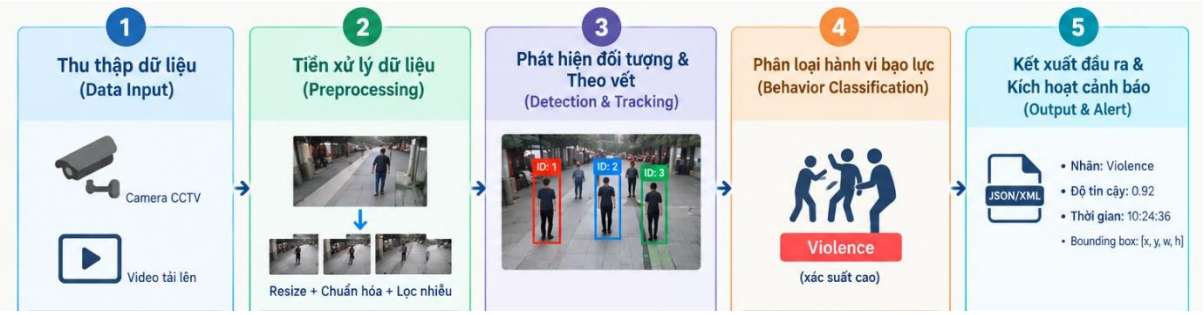
Hình 1. 4 Không bạo lực và bạo lực

Trong bài toán này, dữ liệu đầu vào thường là một video hoặc một chuỗi các khung hình được trích xuất từ video. Hệ thống tiến hành tiền xử lý dữ liệu, trích xuất đặc trưng và đưa các đặc trưng này vào mô hình học sâu để dự đoán nhãn hành vi. Đối với bài toán phân loại nhị phân cơ bản, kết quả đầu ra chia thành hai nhóm:

Violence (Bạo lực): Khi đoạn video/hình ảnh thỏa mãn điều kiện chứa hành vi bạo lực và đã định vị được đối tượng gây ra/chịu tác động của hành vi đó.

Non-Violence (Không bạo lực): Khi đoạn video chỉ chứa các hoạt động tương tác an toàn, bình thường.

Quy trình phát hiện hành vi bạo lực thường bao gồm các bước chính: tiếp nhận dữ liệu video, tiền xử lý, trích xuất đặc trưng không gian và thời gian, phân loại hành vi và đưa ra kết quả dự đoán. Tùy thuộc vào kiến trúc mô hình, quá trình trích xuất đặc trưng có thể được thực hiện trên từng khung hình hoặc trên một chuỗi khung hình liên tiếp nhằm khai thác thông tin chuyển động.



Hình 1. 5 Quy trình tổng quát của bài toán phát hiện hành vi bạo lực

Việc ứng dụng học sâu vào bài toán này cho phép hệ thống tự động học các đặc trưng từ dữ liệu huấn luyện thay vì phải xây dựng hoàn toàn các quy tắc nhận dạng thủ công. Đây là cơ sở để phát triển các hệ thống phân tích video có khả năng nhận dạng những tình huống phức tạp hơn, đồng thời hỗ trợ công tác giám sát và phát hiện sự cố.

1.2. Ứng dụng bài toán

Phát hiện hành vi bạo lực bằng học sâu có thể được ứng dụng trong nhiều lĩnh vực, đặc biệt là những môi trường cần theo dõi an ninh và phát hiện các sự cố có khả năng gây ảnh hưởng đến con người.

Trong hệ thống giám sát an ninh công cộng, các mô hình phát hiện hành vi bạo lực có thể được tích hợp vào hệ thống camera tại đường phố, quảng trường và các khu vực công cộng. Khi phát hiện video có dấu hiệu bạo lực, hệ thống có thể tạo cảnh báo để nhân viên giám sát kiểm tra và xác minh. Điều này giúp hỗ trợ quá trình theo dõi nhiều luồng video và giảm sự phụ thuộc vào quan sát liên tục của con người.

Trong trường học và cơ sở giáo dục, hệ thống có thể hỗ trợ giám sát các khu vực như hành lang, sân trường và khu vực sinh hoạt chung nhằm phát hiện những tình huống xô xát hoặc hành vi bạo lực học đường. Việc phát hiện sớm có thể giúp người có trách nhiệm kiểm tra tình huống và xem xét biện pháp can thiệp phù hợp. Tuy nhiên, kết quả tự động nhận dạng cần được con người xác minh trước khi đưa ra kết luận về sự việc.

Trong trung tâm thương mại và các cơ sở kinh doanh, hệ thống phát hiện hành vi bạo lực có thể hỗ trợ theo dõi các khu vực có mật độ người qua lại cao. Khi xuất hiện những tình huống bất thường, hệ thống có thể thông báo cho bộ phận an ninh để kiểm tra hình ảnh và xử lý theo quy trình của đơn vị.

Trong lĩnh vực giao thông và quản lý đô thị, công nghệ này có tiềm năng hỗ trợ phát hiện những vụ xô xát phát sinh tại các tuyến đường, bãi đỗ xe và khu vực giao thông công cộng. Dữ liệu video được phân tích tự động có thể giúp xác định những đoạn video cần được ưu tiên kiểm tra.



Hình 1. 6 Một số môi trường ứng dụng hệ thống phát hiện hành vi bạo lực

Nhìn chung, việc ứng dụng học sâu trong phát hiện hành vi bạo lực có thể hỗ trợ nâng cao hiệu quả giám sát, rút ngắn thời gian phát hiện các tình huống cần chú ý và khai thác tốt hơn dữ liệu video. Tuy nhiên, hệ thống cần được thiết kế phù hợp với từng môi trường, đồng thời bảo đảm quyền riêng tư và có cơ chế xác minh kết quả để hạn chế những cảnh báo không chính xác.

1.3. Khó khăn và thách thức

Mặc dù các phương pháp học sâu đã đạt được nhiều tiến bộ trong lĩnh vực nhận dạng hình ảnh và video, bài toán phát hiện hành vi bạo lực vẫn tồn tại nhiều khó khăn liên quan đến dữ liệu, đặc điểm hành vi và yêu cầu xử lý.

Thách thức đầu tiên là sự tương đồng giữa hành vi bạo lực và hành vi thông thường. Một số hoạt động như chơi thể thao, vui đùa, tập luyện võ thuật hoặc tương tác giữa nhiều người có thể có đặc điểm chuyển động tương tự hành vi bạo lực. Nếu mô hình chỉ dựa vào những đặc trưng hình ảnh đơn giản, hệ thống có thể phân loại nhầm những hoạt động thông thường thành hành vi bạo lực hoặc bỏ sót các tình huống bạo lực thực sự.

Thách thức thứ hai là đặc điểm không gian và thời gian của dữ liệu video. Hành vi bạo lực không chỉ được thể hiện qua hình dạng và vị trí của đối tượng mà còn phụ thuộc vào sự thay đổi tư thế, hướng di chuyển, tốc độ chuyển động và sự tương tác giữa các đối tượng. Vì vậy, mô hình cần có khả năng khai thác thông tin theo thời gian để nhận dạng chính xác hơn diễn biến của hành động.

Thách thức thứ ba liên quan đến chất lượng và tính đa dạng của dữ liệu. Video giám sát có thể được ghi lại trong nhiều điều kiện khác nhau về ánh sáng, góc quay, độ phân giải và khoảng cách từ camera đến đối tượng. Ngoài ra, hiện tượng che khuất khi có nhiều người xuất hiện trong cùng một khung hình cũng gây khó khăn cho quá trình trích xuất đặc trưng. Nếu tập dữ liệu huấn luyện không đại diện cho các điều kiện thực tế, khả năng tổng quát hóa của mô hình có thể bị hạn chế.

Thách thức tiếp theo là sự mất cân bằng dữ liệu. Trong một số bộ dữ liệu, số lượng video chứa hành vi bạo lực và video không bạo lực có thể chênh lệch đáng kể. Điều này có thể khiến mô hình thiên về lớp chiếm đa số, dẫn đến khả năng nhận dạng kém đối với lớp thiểu số.

Bên cạnh đó, yêu cầu về tốc độ xử lý và tài nguyên tính toán cũng là một vấn đề quan trọng. Các mô hình học sâu, đặc biệt là những kiến trúc phân tích video theo thời gian, có thể yêu cầu bộ nhớ và năng lực tính toán đáng kể. Trong các ứng dụng giám sát, việc xử lý video với độ trễ thấp là yếu tố cần được cân nhắc. Do đó, cần có sự cân

bằng giữa độ chính xác, kích thước mô hình, tốc độ suy luận và khả năng triển khai trên phần cứng.

Cuối cùng, khả năng giải thích và độ tin cậy của kết quả dự đoán cũng là vấn đề cần quan tâm. Một mô hình có thể đưa ra dự đoán hành vi bạo lực nhưng không phải lúc nào cũng thể hiện rõ những đặc trưng dẫn đến kết quả đó. Trong môi trường giám sát thực tế, việc phụ thuộc hoàn toàn vào dự đoán tự động có thể dẫn đến các cảnh báo sai hoặc đánh giá không chính xác về một tình huống. Vì vậy, kết quả của hệ thống nên được sử dụng như thông tin hỗ trợ, kết hợp với quá trình kiểm tra và xác minh của con người.

1.4. Kết luận chương

Trình bày tổng quan về bài toán phát hiện hành vi bạo lực từ dữ liệu video, bao gồm khái niệm, mục tiêu, quy trình xử lý cơ bản và các ứng dụng trong lĩnh vực giám sát an ninh. Nội dung chương đã làm rõ sự khác biệt giữa nhận dạng đối tượng và nhận dạng hành vi, đặc biệt là yêu cầu khai thác thông tin chuyển động và diễn biến theo thời gian trong quá trình phát hiện hành vi bạo lực.

Bên cạnh đó, chương cũng phân tích những khó khăn và thách thức của bài toán, bao gồm sự tương đồng giữa các loại hành vi, tính đa dạng của dữ liệu video, hiện tượng mất cân bằng dữ liệu, yêu cầu về tài nguyên tính toán và độ tin cậy của kết quả dự đoán.

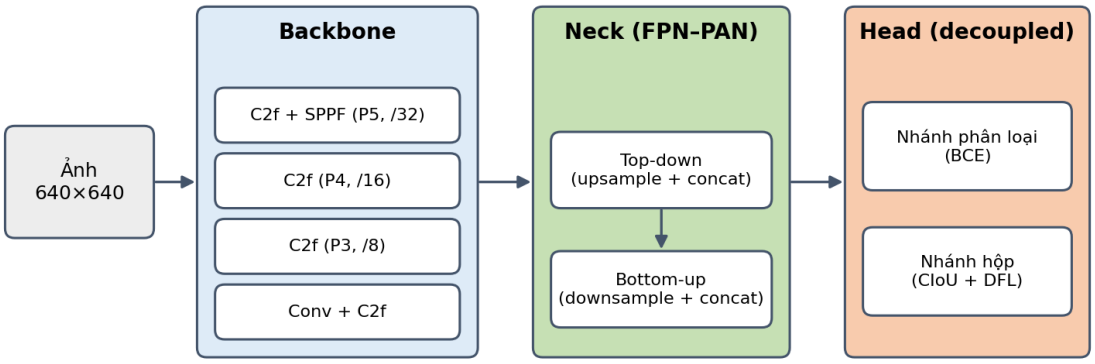
CHƯƠNG 2: TÌM HIỂU CÁC KỸ THUẬT HỌC SÂU

2.1. YOLOv8

2.1.1. Kiến trúc

YOLO (You Only Look Once) coi phát hiện đối tượng là một bài toán hồi quy duy nhất: mạng dự đoán đồng thời hộp giới hạn và xác suất lớp chỉ với một lần lan truyền xuôi nên đạt tốc độ thời gian thực [2]. YOLOv8 do Ultralytics phát hành năm 2023 [3] và được dùng ở cả hai hướng của đồ án: phát hiện trực tiếp Violence/NonViolence (1 stage) và phát hiện người ở Stage 1 (2 stage). Kiến trúc gồm ba khối (Hình 2.1):

- Backbone: CSPDarknet với module C2f, xuất đặc trưng ở ba tỉ lệ P3, P4, P5 (stride 8, 16, 32).
- Neck: FPN–PAN [4] [5]hợp nhất đặc trưng theo cả hai chiều top-down và bottom-up để nhận diện tốt đối tượng ở nhiều kích thước.
- Head: tách riêng nhánh phân loại và nhánh hồi quy hộp (decoupled head), không dùng anchor (anchor-free).



Hình 2. 1 Kiến trúc tổng quát của YOLOv8

Phiên bản YOLOv8n (nano) chỉ có khoảng 3,2 triệu tham số, được chọn để ưu tiên tốc độ suy luận [3].

2.1.2. Hàm mất mát

Hàm mất mát là tổng có trọng số của ba thành phần [3]:

$$L = \lambda_{box} \cdot L_{CIoU} + \lambda_{dfl} \cdot L_{DFL} + \lambda_{cls} \cdot L_{BCE} \quad (2.1)$$

L_{CIoU} đo sai lệch giữa hộp dự đoán và hộp thật, có xét thêm khoảng cách tâm và tỉ lệ khung hình [6]:

$$L_{CIoU} = 1 - IoU + \rho^2(b, b^{gt}) / c^2 + \alpha \cdot v \quad (2.2)$$

$$v = (4/\pi^2) \cdot (\arctan(w^{gt}/h^{gt}) - \arctan(w/h))^2 \quad (2.3)$$

$$\alpha = v / ((1 - IoU) + v) \quad (2.4)$$

trong đó ρ là khoảng cách Euclid giữa tâm hộp dự đoán b và hộp thật b^{gt}, c là đường chéo hộp nhỏ nhất bao cả hai hộp, w và h là chiều rộng và chiều cao. L_{DFL} (Distribution Focal Loss) [7] học phân phối rời rạc của các cạnh hộp để định vị chính xác hơn:

$$L_{DFL} = -[(y_{i+1} - y) \cdot \log(S_i) + (y - y_i) \cdot \log(S_{i+1})] \quad (2.5)$$

với y là giá trị đích nằm giữa hai mức rời rạc y_i và y_{i+1}, S_i là xác suất dự đoán tại mức i. Nhánh phân loại dùng Binary Cross-Entropy:

$$L_{BCE} = -[y \cdot \log(p) + (1 - y) \cdot \log(1 - p)] \quad (2.6)$$

Ngoài ra, YOLOv8 chọn mẫu dương bằng Task-Aligned Assigner [8], dựa trên mức khớp giữa điểm phân loại và chất lượng hộp dự đoán.

2.1.3. Điểm cải tiến so với YOLOv5

So với YOLOv5 [9], YOLOv8 thay đổi ở cả kiến trúc lẫn cách gán mẫu huấn luyện (Bảng 2.1).

Bảng 2. 1 Những điểm mới của YOLOv8 so với YOLOv5

Thành phần	YOLOv5	YOLOv8
Dự đoán hộp	Dựa trên anchor	Anchor-free, dự đoán trực tiếp vị trí và kích thước
Head	Gộp chung, có nhánh objectness	Tách riêng phân loại và hồi quy, bỏ objectness

Khối backbone	C3	C2f
Gán mẫu dương	Ghép theo tỉ lệ kích thước anchor	Task-Aligned Assigner
Loss hộp	CIoU	CIoU + DFL

Ngoài ra, Ultralytics tắt tăng cường mosaic ở những epoch cuối ($close_{m}osaic$) để mô hình thích nghi với phân bố ảnh thật trước khi kết thúc huấn luyện [3].

2.2. EfficientDet-D0

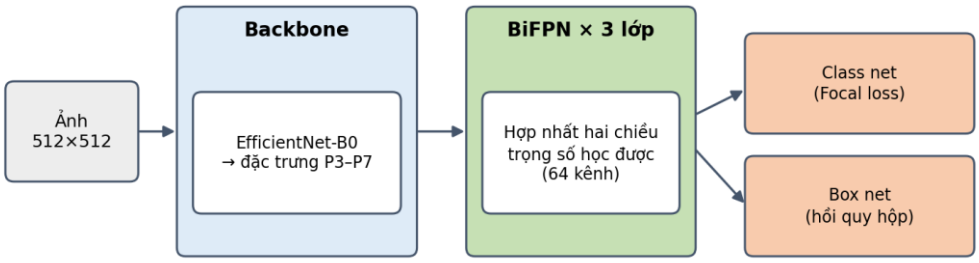
2.2.1. Kiến trúc

EfficientDet [10] là họ mô hình phát hiện đối tượng mở rộng theo hiệu năng (D0–D7). Đồ án dùng bản nhẹ nhất D0 làm mô hình 1 stage thứ hai, đặt cạnh YOLOv8n để so sánh hai kiến trúc detect cùng phân khúc khoảng 3–4 triệu tham số. Kiến trúc gồm ba phần (Hình 2.2): backbone EfficientNet-B0 [11]; neck BiFPN (Bidirectional Feature Pyramid Network); và hai mạng dự đoán dùng chung cho mọi mức đặc trưng là class net và box net.

BiFPN cải tiến FPN bằng kết nối hai chiều và gán trọng số học được cho từng nhánh đầu vào, vì các đặc trưng ở độ phân giải khác nhau đóng góp không đều. Phép hợp nhất chuẩn hóa nhanh (fast normalized fusion) [10]:

$$O = \Sigma_i \left(w_i / (\varepsilon + \Sigma_j w_j) \right) \cdot I_i \qquad (2.7)$$

với I_i là đặc trưng đầu vào, $w_i \geq 0$ là trọng số học được (qua ReLU) và $\varepsilon = 0{,}0001$ để ổn định số học.



Hình 2. 2 Kiến trúc EfficientDet-D0

D0 nhận ảnh 512×512, dùng BiFPN 3 lớp 64 kênh, có khoảng 3,9 triệu tham số và đạt 34,6 AP trên COCO [10].

2.2.2. Hàm mất mát

EfficientDet là mô hình dựa trên anchor. Nhánh phân loại dùng Focal Loss [12] để giảm ảnh hưởng của số lượng lớn mẫu nền dễ phân loại:

$$FL(p_t) = -\alpha_t \cdot (1 - p_t)^{\gamma} \cdot \log(p_t) \quad (2.8)$$

với p_t là xác suất dự đoán của lớp đúng, γ là hệ số tập trung vào mẫu khó và α_t là hệ số cân bằng lớp (bài báo gốc chọn $\gamma = 2$, $\alpha = 0{,}25$ [12]). Nhánh hồi quy hộp dùng hàm mất mát Huber.

2.2.3. Điểm cải tiến so với FPN và NAS-FPN

- Hợp nhất đặc trưng hiệu quả hơn: FPN [3] chỉ truyền thông tin một chiều từ trên xuống, PANet [5] bổ sung chiều ngược lại nhưng tốn chi phí, còn NAS-FPN [13] có cấu trúc do tìm kiếm tự động nên không đều và khó tái sử dụng. BiFPN loại bỏ các nút chỉ có một đầu vào (đóng góp ít), thêm cạnh nối tắt từ đầu vào cùng mức và lặp lại khối như một lớp có thể xếp chồng [10].
- Trọng số học được: mỗi nhánh đầu vào có một trọng số riêng thay vì cộng đều như FPN.
- Compound scaling cho bài toán detect: các detector trước đó thường chỉ mở rộng riêng backbone hoặc kích thước ảnh; EfficientDet mở rộng đồng thời backbone, BiFPN, head và độ phân giải bằng một hệ số φ duy nhất [10].
- Kết quả: đạt độ chính xác cao hơn với số tham số và FLOPs ít hơn đáng kể so với các detector cùng thời [10].

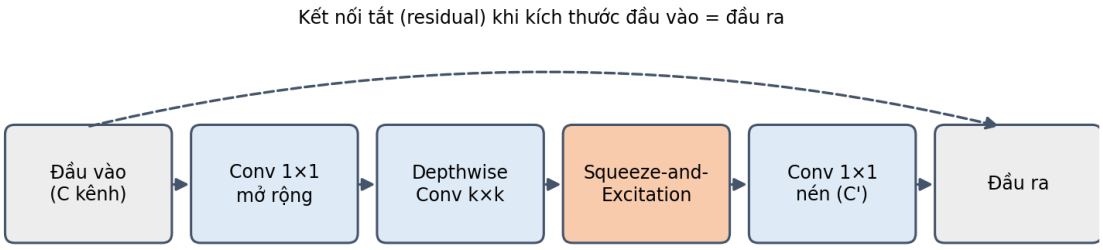
2.3. EfficientNet-B0

2.3.1. Kiến trúc

EfficientNet [11] là họ mạng CNN có kiến trúc cơ sở được tìm bằng NAS rồi mở rộng theo phương pháp compound scaling: tăng đồng thời độ sâu d, độ rộng w và độ phân giải r theo một hệ số φ duy nhất:

$$d = \alpha^{\varphi},\ \ w = \beta^{\varphi},\ \ r = \gamma^{\varphi},\ \ \alpha \cdot \beta^2 \cdot \gamma^2 \approx 2 \quad (2.9)$$

Ràng buộc trên làm chi phí tính toán tăng xấp xỉ 2^{φ} lần; bài báo gốc chọn $\alpha = 1{,}2$, $\beta = 1{,}1$, $\gamma = 1{,}15$ [11]. Khối cơ bản là MBConv kết hợp module Squeeze-and-Excitation (SE) [14] (Hình 2.3), trong đó SE học trọng số riêng cho từng kênh để nhấn mạnh kênh đặc trưng quan trọng. B0 là mạng gốc, khoảng 5,3 triệu tham số, đạt 77,1% top-1 trên ImageNet [11].



Hình 2. 3 Khối MBConv kèm Squeeze-and-Excitation (dùng trong EfficientNet và MobileNetV3)

2.3.2. Điểm cải tiến so với các mạng trước

- Mở rộng cân bằng ba chiều: các mạng trước thường chỉ tăng một chiều, như độ sâu (ResNet [15]), độ rộng hoặc độ phân giải, và hiệu quả bão hòa nhanh. Compound scaling tăng cả ba theo cùng một hệ số nên đạt độ chính xác cao hơn với chi phí tăng có kiểm soát [11].
- Kiến trúc cơ sở tìm bằng NAS với mục tiêu tối ưu đồng thời độ chính xác và FLOPs, tương tự MnasNet [16], sử dụng MBConv và SE.
- Hiệu quả: B0 đạt 77,1% top-1 với 5,3 triệu tham số và 0,39 tỷ FLOPs, trong khi ResNet-50 đạt 76,0% với 26 triệu tham số và 4,1 tỷ FLOPs [11].

2.3.3. Vai trò và cách huấn luyện

EfficientNet-B0 là bộ phân loại Stage 2: nhận vùng ảnh chứa người tương tác do YOLOv8n cắt ra và dự đoán nhãn Violence/NonViolence. Mạng được khởi tạo từ trọng số tiền huấn luyện trên ImageNet và tinh chỉnh cho bài toán hai lớp theo phương pháp học chuyển giao [17]: các lớp đầu học đặc trưng mức thấp (cạnh, kết cấu) có tính tổng quát cao nên được tái sử dụng. Hàm mất mát là Cross-Entropy trên đầu ra softmax [18]:

$$L_{CE} = -\Sigma_{k=1}^{K} y_k \cdot \log(\hat{y}_k), \quad \hat{y}_k = \exp(z_k) / \Sigma_j \exp(z_j) \tag{2.10}$$

với K = 2 lớp, z là vector logit và y là nhãn one-hot.

2.4. MobileNetV3-Large

2.4.1. Kiến trúc

MobileNetV3 [19] là mạng CNN nhẹ cho thiết bị di động, kết hợp bốn thành phần: tích chập tách biệt theo chiều sâu (depthwise separable convolution) [20]; khối inverted residual với linear bottleneck của MobileNetV2 [21]; module SE [14]; và hàm kích hoạt h-swish. Cấu trúc mạng được tinh chỉnh bằng NAS. Tích chập tách biệt theo chiều sâu giảm chi phí so với tích chập chuẩn theo tỉ lệ [20]:

$$(D_K^2 \cdot M \cdot D_F^2 + M \cdot N \cdot D_F^2) / (D_K^2 \cdot M \cdot N \cdot D_F^2) = 1/N + 1/D_K^2 \qquad (2.11)$$

với D_K là kích thước kernel, M và N là số kênh vào và ra, D_F là kích thước bản đồ đặc trưng; với kernel 3×3, chi phí giảm khoảng 8–9 lần. Hàm h-swish là xấp xỉ rẻ hơn của swish [19]:

$$h\text{-}swish(x) = x \cdot ReLU6(x + 3) / 6 \qquad (2.12)$$

2.4.2. Điểm cải tiến so với MobileNetV1 và MobileNetV2

- MobileNetV1 [20] đưa vào tích chập tách biệt theo chiều sâu; MobileNetV2 [20] bổ sung khối inverted residual và linear bottleneck.
- MobileNetV3 thêm module SE (dùng hard-sigmoid) vào khối bottleneck và dùng h-swish thay ReLU ở các lớp sâu để tăng độ chính xác với chi phí thấp.
- Cấu trúc mạng được tìm bằng NAS theo phần cứng (platform-aware NAS) kết hợp NetAdapt, đồng thời thiết kế lại các lớp đầu và cuối vốn tốn nhiều tính toán [19].
- Kết quả: MobileNetV3-Large đạt 75,2% top-1, cao hơn MobileNetV2 (72,0%) 3,2 điểm phần trăm và giảm độ trễ khoảng 20% [19].

2.4.3. Vai trò và so sánh với EfficientNet-B0

MobileNetV3-Large là bộ phân loại Stage 2 thứ hai, được huấn luyện cùng quy trình với EfficientNet-B0 để so sánh công bằng. Bản Large có khoảng 5,4 triệu tham số

và đạt 75,2% top-1 trên ImageNet [19]. Bảng 2.2 tổng hợp hai bộ phân loại theo số liệu công bố gốc.

Bảng 2. 2 So sánh hai mô hình phân loại Stage 2

Tiêu chí	EfficientNet-B0	MobileNetV3-Large
Số tham số	≈ 5,3 triệu [10]	≈ 5,4 triệu [18]
Chi phí tính toán	≈ 0,39 tỷ FLOPs	≈ 219 triệu MAdds
Top-1 ImageNet	77,1%	75,2%
Khối cơ bản	MBConv + SE	Inverted residual + SE
Hàm kích hoạt	Swish	ReLU và h-swish

2.5. Các độ đo đánh giá

2.5.1. Độ đo phân loại

Với lớp Violence là lớp dương, kết quả được đánh giá từ bốn giá trị: TP (bạo lực được dự đoán đúng), TN (không bạo lực được dự đoán đúng), FP (báo động giả) và FN (bỏ sót bạo lực). Các độ đo được tính như sau [22]:

$$Accuracy = (TP + TN) / (TP + TN + FP + FN) \quad (2.13)$$

$$Precision = TP / (TP + FP) \quad (2.14)$$

$$Recall = TP / (TP + FN) \quad (2.15)$$

$$F1 = 2 \cdot Precision \cdot Recall / (Precision + Recall) \quad (2.16)$$

Bỏ sót một tình huống bạo lực (FN) thường nghiêm trọng hơn một báo động giả (FP), vì vậy Recall và F1 được quan tâm bên cạnh Accuracy. Để so sánh công bằng giữa hai hướng, kết quả các mô hình được quy về mức ảnh: ảnh được gán nhãn Violence khi độ tin cậy bạo lực vượt ngưỡng τ, với τ chọn trên tập validation và đánh giá một lần trên tập test.

2.5.2. Độ đo phát hiện đối tượng

Với các mô hình detect (YOLOv8n, EfficientDet-D0), chất lượng định vị được đo bằng IoU giữa hộp dự đoán A và hộp thật B:

$$IoU = |A \cap B| / |A \cup B| \quad (2.17)$$

Average Precision (AP) là diện tích dưới đường cong Precision–Recall của từng lớp [23]; mAP là trung bình AP trên C lớp:

$$AP = \int_0^1 P(R)\, dR, \quad mAP = (1/C)\cdot \Sigma_{c=1}^{C} AP_c \quad (2.18)$$

mAP@0.5 tính tại ngưỡng IoU = 0,5; mAP@0.5:0.95 lấy trung bình trên các ngưỡng từ 0,5 đến 0,95 (bước 0,05) theo chuẩn COCO [24].

CHƯƠNG 3: XÂY DỰNG MÔ HÌNH PHÁT HIỆN BẠO LỰC XÃ HỘI

3.1. Thu thập dữ liệu, khảo sát và tiền xử lý

3.1.1. Giới thiệu bộ dữ liệu

Dữ liệu sử dụng trong đề tài được lấy từ Roboflow, dự án violence-bblcr phiên bản 2, ở định dạng YOLO cho bài toán phát hiện đối tượng. Bộ dữ liệu gồm hai lớp NonViolence (ID 0) và Violence (ID 1), được chia sẵn thành ba tập train, valid và test. Mỗi ảnh có một tệp nhãn YOLO tương ứng. Đây là các khung hình được trích xuất từ video, nên dữ liệu mang những đặc trưng thực tế của bài toán giám sát như nhiều người trong cùng khung hình, che khuất, thay đổi ánh sáng và khác biệt về khoảng cách tới camera [25].

Bảng 3. 1 Quy mô bộ dữ liệu theo từng tập

Tập	Số ảnh	Số file nhãn	Tỷ lệ
Train	26.013	26.013	92,1%
Validation	1.497	1.497	5,3%
Test	748	748	2,6%
Tổng	28.258	28.258	100%

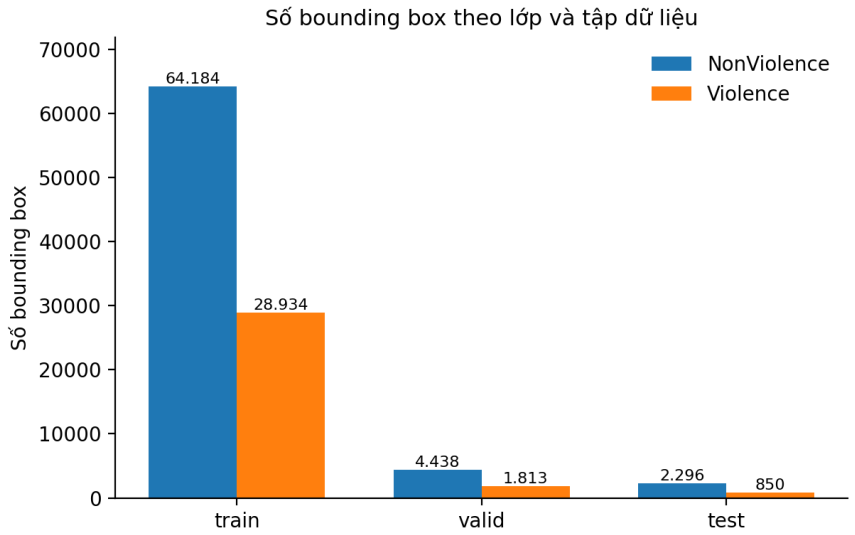
Tập train chiếm phần lớn dữ liệu, trong khi validation và test có quy mô nhỏ hơn. Vì vậy, các chỉ số trên validation và test cần được diễn giải cùng với Precision, Recall và F1-score, thay vì chỉ dựa vào Accuracy.

3.1.2. Phân tích khám phá dữ liệu (EDA)

EDA đóng vai trò quan trọng trong bài toán phát hiện đối tượng. Quá trình này giúp nghiên cứu rõ bản chất của tập dữ liệu. Từ đó, xây dựng chiến lược hợp lý và dễ dàng lựa chọn kiến trúc mô hình và hàm mất mát tối ưu.

Tính chất đa đối tượng: Một bức ảnh đơn lẻ có thể chứa nhiều người cùng xuất hiện. Các đối tượng trong ảnh có thể tương tác với nhau. Do đó, tổng số bounding box thường lớn hơn nhiều so với tổng số ảnh.

Sự xuất hiện đồng thời của các lớp: Một khung hình có thể chứa cả hành vi bạo lực và phi bạo lực cùng một lúc. Ví dụ, một cảnh ẩu đả có người đánh nhau và có cả người đứng xem. Nếu chỉ thống kê ở mức ảnh, mô hình sẽ dễ bị thiên vị. Mô hình cũng có thể bỏ sót các chi tiết nhỏ trong từng vùng ảnh.



Hình 3. 1 Phân bố số bounding box theo lớp và theo tập dữ liệu

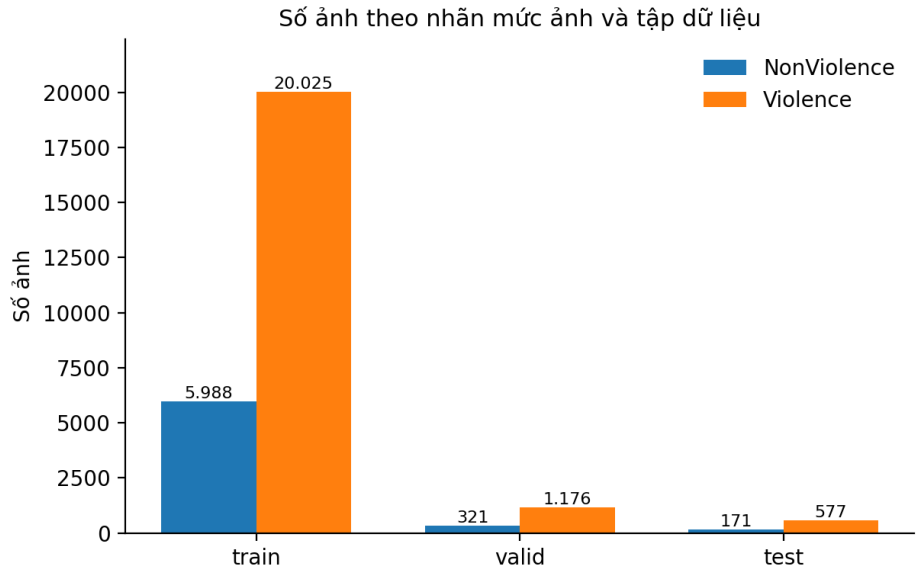
Ở mức bounding box, toàn bộ dữ liệu có 102.515 box, gồm 70.918 box NonViolence (69,2%) và 31.597 box Violence (30,8%), tương ứng tỷ lệ khoảng 2,24 : 1. Trên tập train, tỷ lệ NonViolence : Violence là 2,22 : 1. Mức mất cân bằng này không quá lớn đối với mô hình phát hiện đối tượng.

Bảng 3. 2 Thống kê phân bố lớp ở mức ảnh

Tập	NonViolence	Violence	Tỷ lệ Violence
Train	5.988	20.025	77,0%
Validation	321	1.176	78,6%
Test	171	577	77,1%
Tổng	6.480	21.778	77,1%

Tính đồng nhất giữa các tập: Tỷ lệ ảnh chứa lớp Violence duy trì ổn định khoảng 77,0% đến 78,6% trên cả ba tập. Điều này chứng minh quy trình chia dữ liệu đạt độ chính xác cao. Dữ liệu không bị lệch phân bố giữa tập huấn luyện và tập đánh giá.

Mối tương quan giữa mức ảnh và mức box: Ảnh chứa lớp Violence chiếm ưu thế ở mức ảnh với tỷ lệ 77,1%. Tuy nhiên, bounding box thuộc lớp NonViolence lại chiếm đa số ở mức box với tỷ lệ 69,2%. Hiện tượng này cho thấy các cảnh bạo lực thường chỉ có ít đối tượng tham gia trực tiếp. Trong khi đó, các cảnh phi bạo lực thường có mật độ người xuất hiện đông đúc hơn.



Hình 3. 2 Phân bố số ảnh theo nhãn mức ảnh

Ở mức ảnh, kết quả đảo chiều: 21.778 ảnh (77,1%) chứa ít nhất một box Violence, trong khi 6.480 ảnh (22,9%) chỉ chứa NonViolence. Nguyên nhân là một cảnh bạo lực thường xuất hiện nhiều người trong cùng khung hình nhưng không phải tất cả các box đều mang nhãn Violence. Do đó, Accuracy đơn thuần có thể tạo cảm giác tốt hơn thực tế; trong đánh giá cần xem đồng thời Precision, Recall và F1-score của lớp Violence.

Bảng 3. 3 Một số đặc trưng hình học của bounding box

Đại lượng	NonViolence	Violence
Chiều rộng w, trung bình	0,125 ± 0,089	0,203 ± 0,114

Chiều cao h, trung bình	0,318 ± 0,227	0,427 ± 0,231
Diện tích A, trung vị	0,035	0,078
Tỷ lệ w/h, trung vị	0,368	0,459

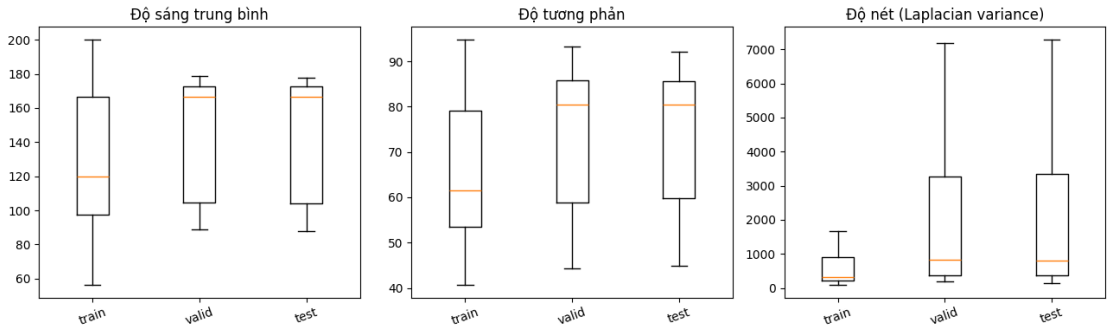
Box Violence có diện tích trung vị lớn hơn khoảng 2,2 lần so với box NonViolence. Đồng thời, khoảng một phần tư box NonViolence có kích thước rất nhỏ (xấp xỉ dưới 32×32 pixel khi quy đổi về ảnh 512×512), tạo ra thách thức cho các mô hình nhẹ và các trường hợp người ở xa camera. Tỷ lệ w/h trung vị 0,37–0,46 cho thấy bounding box có dạng đứng, phù hợp với đối tượng người.

3.1.3. Độ phân giải, chất lượng dữ liệu và rò rỉ

Phân tích trên mẫu ngẫu nhiên 300 ảnh cho mỗi tập cho thấy toàn bộ ảnh trong mẫu có kích thước 512×512 pixel. Như vậy, dữ liệu có định dạng không gian đồng nhất giữa train, validation và test; đây cũng là kích thước native được sử dụng khi tham khảo EfficientDet-D0.

Bảng 3. 4 Thống kê độ phân giải và chất lượng ảnh

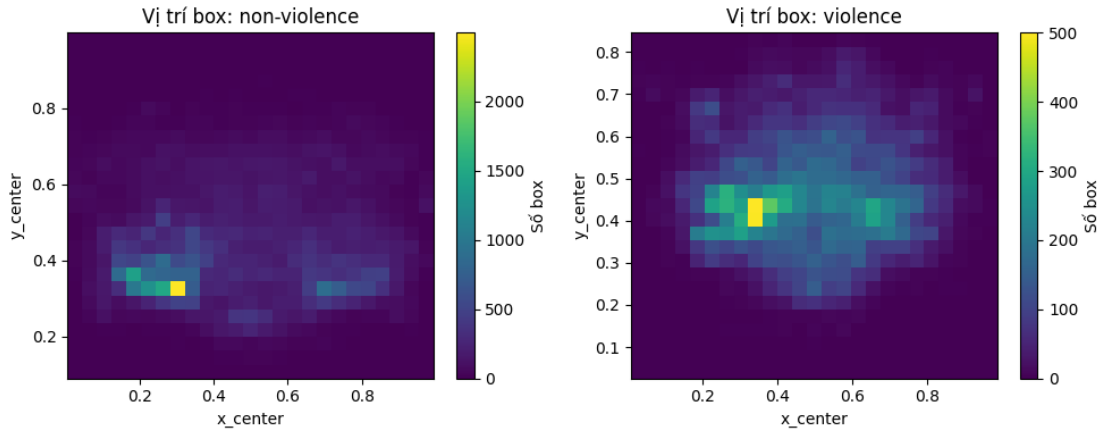
Tập	Độ phân giải mẫu	Độ sáng TB	Tương phản TB	Độ nét trung vị
Train	512×512	127,9	65,0	333
Validation	512×512	145,8	73,7	824
Test	512×512	145,8	73,6	802



Hình 3. 3 Phân bố độ sáng, tương phản và độ nét theo tập dữ liệu

Train có độ sáng và độ tương phản thấp hơn validation/test, đồng thời độ nét trung vị thấp hơn đáng kể. Nguồn gốc của khác biệt này chưa được kiểm chứng hoàn toàn và có thể liên quan đến nguồn video hoặc quá trình tăng cường dữ liệu.

Cấu trúc nhãn cho 28.258 ảnh không phát hiện ảnh hỏng, ảnh thiếu nhãn, nhãn không có ảnh tương ứng hay tệp nhãn sai cấu trúc. Khi kiểm tra MD5 cho thấy có 8 nhóm ảnh trùng nội dung, nhưng không có nhóm nào xuất hiện đồng thời ở từ hai tập trở lên, do đó không phát hiện rò rỉ liên tập ở mức byte giống hệt.



Hình 3. 4 Heatmap vị trí tâm bounding box theo lớp

Tâm bounding box của cả hai lớp tập trung chủ yếu ở vùng giữa khung hình; box Violence có xu hướng tập trung gần trung tâm hơn. Đặc trưng vị trí này có thể khiến mô hình học một phần phụ thuộc vào bố cục camera.

3.1.4. Tiền xử lý và chuẩn bị dữ liệu

Quy trình tiền xử lý được thống nhất theo từng loại mô hình. Với các mô hình phát hiện đối tượng YOLOv8n và EfficientDet-D0, dữ liệu được thay đổi linh hoạt dựa chọn mô hình với yolo sẽ là đinh dạng yolov8 còn efficientDet-D0 sẽ là COCO , sau đó kiểm tra tính hợp lệ của ảnh và nhãn, loại exact duplicate giữa train với validation/test và giữ nguyên frame trong train với frame_stride = 1.

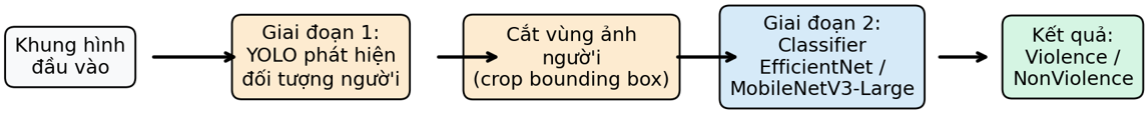
Đối với bộ phân loại, các vùng người được crop từ giai đoạn phát hiện và tổ chức theo cấu trúc train/val/test với hai thư mục lớp non-violence và violence. Ảnh đầu vào được resize về 224×224. Tập train áp dụng RandomHorizontalFlip, RandomRotation,

RandomAffine, ColorJitter và RandomErasing; validation/test chỉ resize và chuẩn hóa theo thống kê ImageNet để tránh làm thay đổi phân phối đánh giá.

3.2. Xây dựng mô hình học sâu

3.2.1. Kiến trúc tổng quát của hệ thống

Hệ thống được triển khai theo hướng hai giai đoạn. Giai đoạn 1 phát hiện người trong khung hình; giai đoạn 2 gom các vùng người liên quan, tạo crop và đưa crop vào bộ phân loại hành vi. Cách tách hai giai đoạn giúp classifier tập trung vào vùng chứa người thay vì toàn bộ nền ảnh.



Hình 3. 5 Kiến trúc tổng quát của pipeline phát hiện bạo lực hai giai đoạn

Trong các notebook thực nghiệm, YOLOv8n được sử dụng làm bộ phát hiện người cho pipeline hai giai đoạn. Các bounding box người được gom theo DBSCAN, tạo crop có padding rồi đưa vào MobileNetV3-Large hoặc EfficientNet-B0. Kết quả mức crop được tổng hợp thành dự đoán mức ảnh bằng xác suất Violence lớn nhất trong các crop.

3.2.2. Giai đoạn 1 - Phát hiện đối tượng với YOLOv8n và EfficientDet-D0

YOLOv8n được chọn làm bộ phát hiện chính nhờ kiến trúc gọn, hỗ trợ suy luận nhanh và dễ tích hợp vào pipeline video. Notebook sử dụng trọng số pretrained, kích thước ảnh 640×640, batch 16, tối đa 80 epoch và patience 15. Trong một lần chạy resume, quá trình được tiếp tục từ checkpoint trước đó và hoàn tất ở epoch 75. Mô hình có khoảng 3,01 triệu tham số và 8,2 GFLOPs theo log huấn luyện.

EfficientDet-D0 được xây dựng như mô hình đối chứng cho giai đoạn phát hiện. Sử dụng backbone tf_efficientdet_d0 với pretrained=True, ảnh 640×640 trong controlled comparison để đồng nhất với YOLOv8n, batch tổng 16 trên hai GPU T4, tối đa 80 epoch, early stopping patience 10 và EMA. Optimizer của thí nghiệm chuẩn là SGD với learning rate 0,01, momentum 0,9 và weight decay 4×10^{-5}. Ngoài cấu hình

baseline, notebook còn chuẩn bị các thử nghiệm learning rate 0,005 và 0,020 và một cấu hình native 512×512 để phân tích ảnh hưởng độ phân giải.

3.2.3. Giai đoạn 2 - Phân loại với MobileNetV3-Large và EfficientNet-B0

Hai classifier được xây dựng trên timm với trọng số pretrained ImageNet và đầu ra hai lớp. Cả hai sử dụng cùng dữ liệu crop và cùng quy trình tăng cường để tạo điều kiện so sánh công bằng. Sự khác biệt chính nằm ở kiến trúc: MobileNetV3-Large hướng tới mô hình nhẹ và hiệu quả tính toán, trong khi EfficientNet-B0 hướng tới khả năng trích xuất đặc trưng với chi phí tính toán vẫn ở mức vừa phải.

Bảng 3. 5 Cấu hình huấn luyện bộ phân loại

Tham số	MobileNetV3-Large	EfficientNet-B0
Kích thước đầu vào	224×224	224×224
Batch size	64	64
Epoch tối đa	50	50
Learning rate đầu	1×10^{-3}	1×10^{-3}
Learning rate unfreeze	3×10^{-5}	3×10^{-5}
Freeze backbone đầu	5 epoch	5 epoch
Optimizer	AdamW	AdamW
Weight decay	0,05	0,05
Dropout	0,3	0,3
Label smoothing	0,1	0,1
Early stopping patience	5	5

Trong 5 epoch đầu, backbone được đóng băng và chỉ huấn luyện phần classifier. Sau đó toàn bộ mạng được mở (unfreeze) với learning rate nhỏ hơn để fine-tune. Scheduler ReduceLROnPlateau được dùng để giảm learning rate khi validation accuracy không cải thiện. Checkpoint tốt nhất được lưu theo validation accuracy và checkpoint đầy đủ được lưu sau mỗi epoch để có thể resume khi phiên Kaggle kết thúc.

3.2.4. Hai cấu hình pipeline hai giai đoạn

Bảng 3. 6 Thiết lập dùng chung cho hai pipeline YOLOv8n + classifier

Thành phần	Thiết lập
Bộ phát hiện	YOLOv8n pretrained, chỉ lớp person (class 0)
Confidence / IoU	0,15 / 0,50
Lọc người nhỏ	Diện tích bounding box ≥ 300 pixel²
Gom người	DBSCAN, eps = 200, min_samples = 1
Crop	Bounding box nhóm người + padding 25%
Classifier	MobileNetV3-Large hoặc EfficientNet-B0
Ngưỡng Violence	Quét trên validation, chọn theo F1
Lưới ngưỡng	0,05 đến 0,95, bước 0,01
Mức đánh giá	Image-level trên test

Hai mô hình kết YOLOv8_MobileNetV3 và YOLOv8_EfficientNet được thiết kế với giao thức test giống nhau: cùng nguồn Roboflow, cùng YOLO person detector, cùng confidence/IoU, DBSCAN, padding, mapping lớp và cách tính metric. Điểm khác biệt duy nhất là classifier ở giai đoạn 2. Ngưỡng phân loại được quét trên validation theo F1 rồi chỉ áp dụng một lần trên test, nhằm tránh chọn ngưỡng trực tiếp trên tập test.

3.2.5. Quy trình huấn luyện và đánh giá

Quy trình thực nghiệm được thực hiện theo thứ tự: (1) kiểm tra và làm sạch dữ liệu; (2) huấn luyện bộ phát hiện trên train và theo dõi validation; (3) lưu checkpoint tốt nhất; (4) huấn luyện hai bộ phân loại trên dữ liệu crop; (5) xây dựng hai pipeline hai giai đoạn; (6) chọn ngưỡng Violence trên validation; và (7) đánh giá một lần trên test. Với detector, các chỉ số chính là mAP@0.50 và mAP@0.50:0.95 cùng Precision/Recall theo lớp. Với pipeline hai giai đoạn, các chỉ số ở mức ảnh gồm Accuracy, Precision, Recall và F1-score của lớp Violence, kèm confusion matrix.

CHƯƠNG 4: KẾT QUẢ THỰC NGHIỆM MÔ HÌNH PHÁT HIỆN HÀNH VI BẠO LỰC

4.1 Môi trường và thiết lập thực nghiệm

4.1.1 Môi trường thực nghiệm

Thực nghiệm được thực hiện trên Kaggle, sử dụng PyTorch và các thư viện hỗ trợ phát hiện đối tượng, phân loại ảnh, gom cụm và tính chỉ số đánh giá. Cấu hình phần cứng được lấy từ hệ thống của kaggle và không có chỉnh sửa gì thêm.

Bảng 4. 1 Môi trường và cấu hình đầu vào

Thành phần	Thiết lập
Nền tảng	Kaggle Notebook
CPU và RAM	Intel Xeon và khoảng 29 GB RAM
GPU huấn luyện detector	2 × NVIDIA Tesla T4, 16 GB mỗi GPU
Framework và thư viện	PyTorch; Ultralytics; effdet; timm; scikit-learn; OpenCV
Đầu vào detector	640 × 640 pixel
Đầu vào classifier	224 × 224 pixel
Nguồn đánh giá	Roboflow violence-bblcr, phiên bản 2

4.1.2 Dữ liệu và giao thức đánh giá

Tập validation gồm 1.497 ảnh; tập test gồm 748 ảnh, trong đó 577 ảnh Violence và 171 ảnh NonViolence. Một ảnh được gán Violence khi có ít nhất một bounding box mang nhãn Violence trong annotation. Lớp Violence được coi là lớp dương khi tính Precision, Recall và F1.

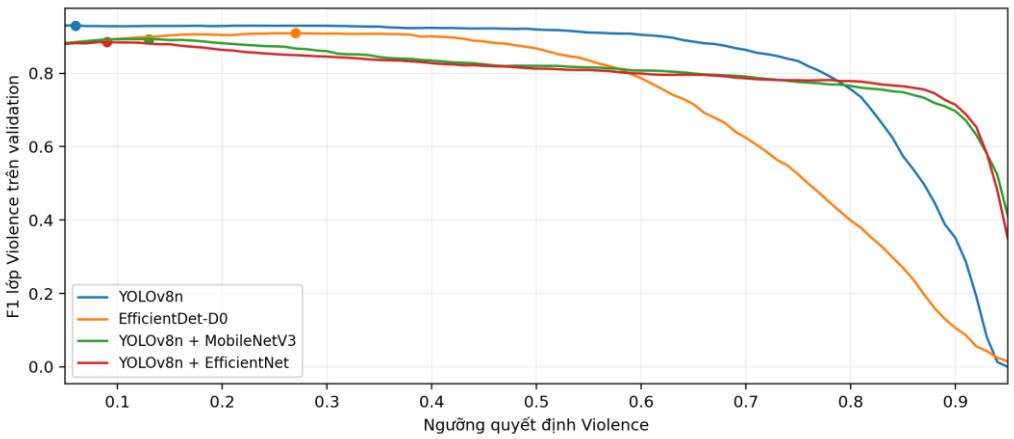
Hai cấp đánh giá được sử dụng. Ở mức đối tượng, mAP@0.50 và mAP@0.50:0.95 đo chất lượng nhận diện và định vị bounding box. Ở mức ảnh, Accuracy, Precision, Recall và F1 đo khả năng kết luận một khung hình có bạo lực hay không. Do khác nhau về đơn vị đánh giá và điều kiện ghép dự đoán với nhãn, mAP không được so sánh trực tiếp với F1 ở mức ảnh.

Điểm Violence của detector là confidence lớn nhất trong các box Violence; điểm của pipeline là xác suất Violence lớn nhất trong các crop hợp lệ. Khi không có box hoặc crop tương ứng, điểm được đặt bằng 0. Ngưỡng được quét trên validation từ 0,05 đến 0,95 với bước 0,01, chọn theo F1 cao nhất; nếu có nhiều ngưỡng cùng đạt cực đại, notebook chọn phần tử giữa trong danh sách các ngưỡng đó. Ngưỡng đã chọn được áp dụng cho test, không tối ưu lại bằng nhãn test.

Bảng 4. 2 Ngưỡng được chọn và kết quả trên validation

Phương án	**Ngưỡng**	**Precision %**	**Recall %**	**F1 %**
YOLOv8n	0,06	90,78	95,41	93,03
EfficientDet-D0	0,27	86,15	96,26	90,92
YOLOv8n + MobileNetV3	0,13	81,49	98,81	89,32
YOLOv8n + EfficientNet	0,09	80,00	98,98	88,48

Các ngưỡng tối ưu đều dưới 0,50. Điều này phản ánh cách phân bố điểm của từng mô hình và tiêu chí chọn F1 trên validation, không có nghĩa xác suất của các mô hình đã được hiệu chỉnh tốt. Việc lựa chọn ngưỡng trên validation hạn chế rò rỉ ở bước ra quyết định; kiểm tra rò rỉ giữa các frame hoặc giữa các video nguồn vẫn là một vấn đề riêng.



Hình 4. 1 F1 trên validation theo ngưỡng quyết định Violence

4.2 Kết quả phát hiện trực tiếp bằng mô hình một giai đoạn

4.2.1 Kết quả định vị và nhận diện đối tượng

Bảng 4. 3 Kết quả detector trên tập test

Mô hình	mAP@0.50 %	mAP@0.50:0.95 %
YOLOv8n	84,64	61,34
EfficientDet-D0	74,64	44,74

Bảng 4.3 là kết quả test mô hình, tương ứng các notebook đánh giá đồng bộ. YOLOv8n đạt mAP@0.50 bằng 84,64% và mAP@0.50:0.95 bằng 61,34%, cao hơn EfficientDet-D0 lần lượt 10,00 và 16,60 điểm phần trăm. Chênh lệch lớn hơn ở metric có nhiều ngưỡng IoU cho thấy chất lượng định vị của YOLOv8n tốt hơn trong lần đánh giá này.

Bảng 4. 4 Chỉ số detector theo lớp trên tập test

Lớp	YOLOv8n AP@0.50 (%)	EfficientDet-D0 AP@0.50 (%)	YOLOv8n AP@0.50:0.95 (%)	EfficientDet-D0 AP@0.50:0.95 (%)
NonViolence	86,24	77,38	60,90	46,11
Violence	83,05	71,90	61,77	43,37

Annotation COCO của EfficientDet-D0 khai báo People-violence như một nhóm cha nhưng không có box test thuộc nhóm này. Tập test có 2.296 box NonViolence và 850 box Violence. Các giá trị 0 của nhóm cha trong JSON không được diễn giải thành một lớp hành vi thứ ba; mAP tổng tương ứng trung bình trên hai lớp có annotation.

YOLOv8n còn lưu một kết quả trước đó với mAP@0.50 = 84,98% và mAP@0.50:0.95 = 61,88%, sử dụng NMS IoU = 0,60. Giao thức Test hiện tại cấu hình NMS IoU = 0,50 và cho kết quả ở Bảng 4.3. Hai lần đánh giá được phân biệt để tránh ghép số liệu của cấu hình cũ với dự đoán mức ảnh của cấu hình hiện tại. Tóm tắt huấn luyện EfficientDet-D0 ghi checkpoint tốt nhất tại epoch 21 và dừng sớm sau 31 epoch.

4.2.2 Kết quả phân loại ở mức ảnh

YOLOv8n dự đoán đúng 642/748 ảnh, đạt Accuracy 85,83% và F1 Violence 91,03%. EfficientDet-D0 dự đoán đúng 631/748 ảnh, đạt Accuracy 84,36% và F1 90,48%. EfficientDet-D0 có Recall cao hơn 3,12 điểm phần trăm, trong khi YOLOv8n có Precision cao hơn 3,65 điểm phần trăm. Vì vậy, YOLOv8n cân bằng tốt hơn giữa phát hiện bạo lực và hạn chế cảnh báo nhầm tại các ngưỡng đã chọn.

Bảng 4. 5 Kết quả mức ảnh của hai detector trên 748 ảnh test

Mô hình	Accuracy %	Precision %	Recall %	F1 %
YOLOv8n	85,83	88,93	93,24	91,03
EfficientDet-D0	84,36	85,28	96,36	90,48

Recall mức ảnh cao hơn Recall mức box là điều có thể xảy ra: một ảnh chỉ cần có một dự đoán Violence vượt ngưỡng để được kết luận dương tính, ngay cả khi các đối tượng khác trong ảnh bị bỏ sót. Chỉ số mức ảnh vì thế không chứng minh mô hình đã định vị đầy đủ các đối tượng bạo lực.

4.3 Kết quả phát hiện người kết hợp phân loại hành vi

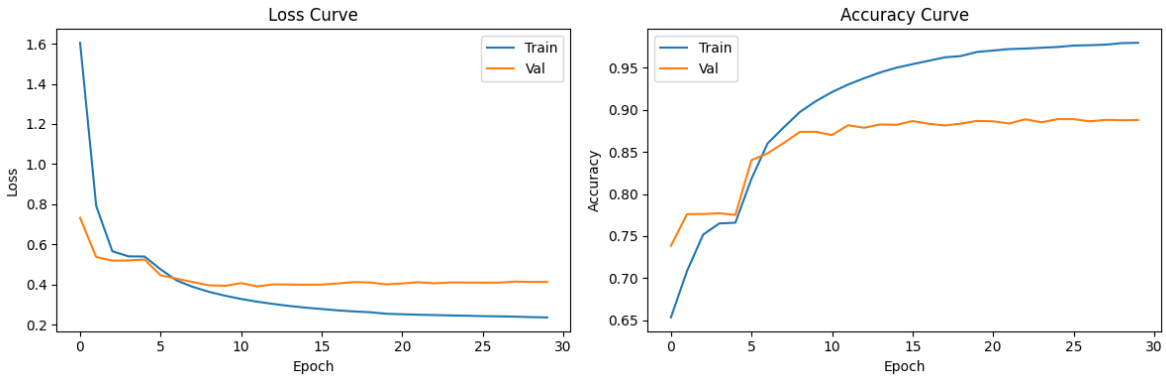
4.3.1 Đánh giá riêng hai bộ phân loại

Kết quả đánh giá classifier riêng trên 3.146 mẫu, gồm 2.296 mẫu NonViolence và 850 mẫu Violence theo ma trận nhầm lẫn. Đơn vị của phép đo này là mẫu phân loại, khác với 748 ảnh của pipeline hoàn chỉnh. Kết quả được báo cáo riêng để tránh dùng Accuracy của classifier thay cho Accuracy toàn hệ thống.

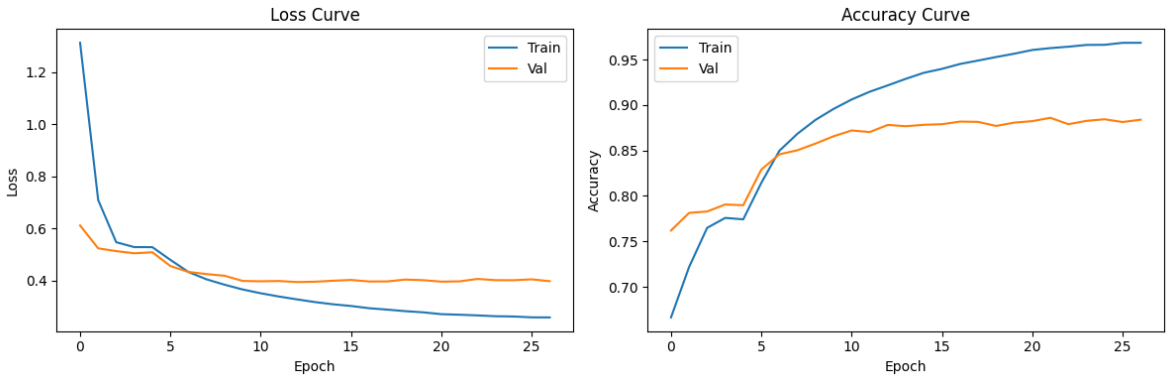
Bảng 4. 6 Kết quả đánh giá riêng classifier

Classifier	Accuracy %	Precision %	Recall %	F1 %
MobileNetV3-Large	88,78	80,12	77,76	78,93
EfficientNet-B0	88,11	80,51	73,88	77,06

MobileNetV3-Large đạt F1 cao hơn 1,87 điểm phần trăm và Recall cao hơn 3,88 điểm phần trăm so với EfficientNet-B0 trên các mẫu phân loại. MobileNetV3-Large bỏ sót 189/850 mẫu Violence và báo nhầm 164 mẫu NonViolence; EfficientNet-B0 bỏ sót 222 mẫu Violence và báo nhầm 152 mẫu NonViolence. Hai mô hình đã được thay đầu ra thành hai lớp: số tham số lưu trong kết quả lần lượt là 4.204.594 và 4.010.110; kích thước tệp mô hình lần lượt khoảng 16,24 MB và 15,58 MB.



Hình 4. 2 Đường loss và accuracy của MobileNetV3-Large



Hình 4. 3 Đường loss và accuracy của EfficientNet-B0

Các đường huấn luyện cho thấy loss train tiếp tục giảm trong khi loss validation ổn định quanh 0,4; Accuracy train tăng tới khoảng 97–98% còn validation chỉ quanh 88–89%. Khoảng cách này phù hợp với dấu hiệu quá khớp và cho thấy thêm epoch không đảm bảo cải thiện khả năng tổng quát hóa. MobileNetV3-Large lưu 27 epoch và best validation accuracy = 88,592%; tệp EfficientNet-B0 để null ở hai trường tương ứng nên không suy đoán epoch tốt nhất từ tóm tắt này.

4.3.2 Kết quả pipeline hoàn chỉnh

Hai pipeline sử dụng YOLOv8n pretrained để phát hiện person, confidence = 0,15, NMS IoU = 0,50, lọc box có diện tích dưới 300 pixel², gom nhóm bằng DBSCAN với eps = 200 và min_samples = 1, rồi tạo crop có padding 25%. Bộ phát hiện người trong pipeline là yolov8n.pt, khác checkpoint best.pt đã fine-tune hai lớp hành vi ở mô hình một giai đoạn.

Pipeline MobileNetV3-Large đạt Recall 98,44%, nhận diện đúng 568/577 ảnh Violence và bỏ sót 9 ảnh. Pipeline EfficientNet-B0 đạt Recall 98,96%, nhận diện đúng 571 ảnh Violence và bỏ sót 6 ảnh. Tuy nhiên, số ảnh NonViolence bị báo nhầm lần lượt là 139/171 và 153/171. Precision thấp hơn đáng kể so với detector trực tiếp khiến F1 của hai pipeline chỉ đạt 88,47% và 87,78%.

Bảng 4. 7 Kết quả mức ảnh của hai pipeline trên tập test

Pipeline	Ngưỡng	Accuracy %	Precision %	Recall %	F1 %
YOLOv8n+MobileNetV3	0,13	80,21	80,34	98,44	88,47
YOLOv8n + EfficientNet	0,09	78,74	78,87	98,96	87,78

Hai pipeline đều ghi nhận 2.814 box người, 847 nhóm và 847 crop hợp lệ trên tập test. Có 4 ảnh không phát hiện được người và không tạo được crop; theo mã nguồn, các ảnh này nhận điểm Violence bằng 0. Chưa thể quy toàn bộ lỗi bỏ sót cho bước phát hiện người, vì còn có thể phát sinh lỗi do gom nhóm, cắt vùng hoặc classifier.

Quy tắc lấy xác suất lớn nhất và các ngưỡng thấp 0,13/0,09 khiến chỉ một crop vượt ngưỡng cũng đủ tạo cảnh báo toàn ảnh. Đây là một cơ chế có thể góp phần làm Recall cao và Precision thấp. Việc khẳng định nguyên nhân cụ thể cần xem lại từng ảnh lỗi hoặc làm thí nghiệm ablation; các tệp dự đoán hiện tại chỉ xác nhận sự đánh đổi giữa hai loại lỗi.

4.4 So sánh và phân tích kết quả

4.4.1 So sánh tổng thể trên cùng tập test

YOLOv8n đứng đầu về Accuracy, Precision và F1 trong các phương án đã lưu. F1 của YOLOv8n cao hơn pipeline MobileNetV3-Large 2,56 điểm phần trăm và cao hơn pipeline EfficientNet-B0 3,25 điểm phần trăm. EfficientDet-D0 đứng thứ hai về F1 mức ảnh dù mAP mức box thấp hơn nhiều; điều này một lần nữa cho thấy hai cấp đánh giá phản ánh hai yêu cầu khác nhau.

Bảng 4. 8 So sánh bốn phương án ở mức ảnh

Phương án	Accuracy %	Precision %	Recall %	F1 %
YOLOv8n	85,83	88,93	93,24	91,03
EfficientDet-D0	84,36	85,28	96,36	90,48
YOLOv8n + MobileNetV3	80,21	80,34	98,44	88,47
YOLOv8n + EfficientNet	78,74	78,87	98,96	87,78

Do 77,14% ảnh test mang nhãn Violence, một phương án luôn dự đoán Violence đã đạt Accuracy 77,14% và F1 Violence khoảng 87,09%, nhưng báo nhầm toàn bộ 171 ảnh NonViolence. Vì vậy, F1 cao trong dữ liệu mất cân bằng cần được đọc cùng số false positive, khả năng nhận diện NonViolence và ma trận nhầm lẫn. Accuracy 78,74% của pipeline EfficientNet-B0 chỉ cao hơn baseline này khoảng 1,60 điểm phần trăm.

4.2.2 Ma trận nhầm lẫn và hai loại lỗi

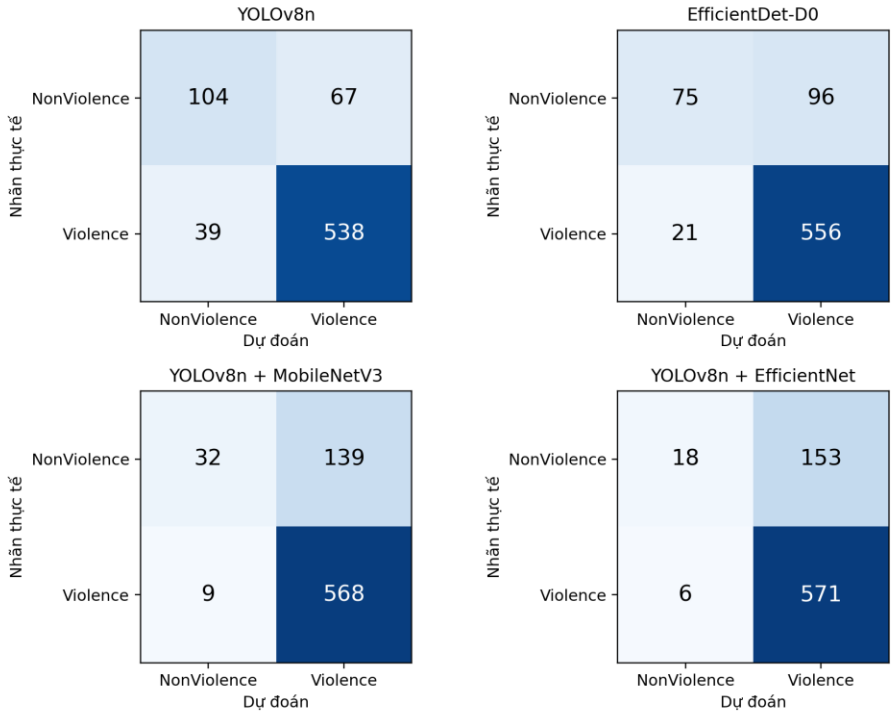
Bảng 4. 9 Số lỗi và khả năng nhận diện NonViolence

Phương án	TN	FP	FN	TP	Specificity %
YOLOv8n	104	67	39	538	60,82
EfficientDet-D0	75	96	21	556	43,86
YOLOv8n + MobileNetV3	32	139	9	568	18,71

YOLOv8n + EfficientNet	18	153	6	571	10,53

Trong Bảng 4.9, TN là ảnh NonViolence được dự đoán đúng, FP là ảnh NonViolence bị báo bạo lực, FN là ảnh Violence bị bỏ sót và TP là ảnh Violence được nhận diện đúng. Specificity = TN/(TN + FP) đo tỷ lệ nhận diện đúng NonViolence. YOLOv8n đạt 60,82%, EfficientDet-D0 đạt 43,86%; hai pipeline chỉ đạt 18,71% và 10,53%. Đây là hạn chế quan trọng khi ứng dụng vào camera có phần lớn thời gian không xảy ra bạo lực.

So với YOLOv8n, pipeline MobileNetV3-Large giảm 30 ảnh bỏ sót nhưng tăng 72 ảnh báo nhầm; pipeline EfficientNet-B0 giảm 33 ảnh bỏ sót nhưng tăng 86 ảnh báo nhầm. Lựa chọn phương án vì thế phụ thuộc chi phí thực tế của việc bỏ sót và cảnh báo giả. Nếu ưu tiên cân bằng ở mức ảnh, YOLOv8n là lựa chọn phù hợp với số liệu hiện tại. Nếu ưu tiên giảm bỏ sót, có thể xem xét pipeline hai giai đoạn nhưng cần bổ sung xác nhận theo thời gian hoặc hiệu chỉnh ngưỡng trên một tập validation đại diện cho môi trường triển khai.



Hình 4. 4 Ma trận nhầm lẫn mức ảnh của bốn phương án.

4.4.3 Thời gian xử lý và giới hạn phép đo

Bảng 4. 10 Thời gian chạy pipeline được lưu trong tệp summary

Pipeline	Thời gian(s)	Trung bình ms mỗi ảnh	Thông lượng ảnh mỗi (s)
YOLOv8n + MobileNetV3	17,00	22,73	43,99
YOLOv8n + EfficientNet	19,86	26,56	37,66

Các đại lượng trong Bảng 4.10 được quy đổi từ runtime_seconds của vòng lặp xử lý 748 ảnh: thời gian trung bình = tổng thời gian/748 và thông lượng = 748/tổng thời gian. Phép đo bao gồm đọc ảnh, phát hiện người, gom nhóm, tạo crop và phân loại trong vòng lặp; không bao gồm toàn bộ bước tải dữ liệu hoặc khởi tạo mô hình.

Thông lượng MobileNetV3 cao hơn, nhưng chưa đủ để kết luận chênh lệch hoàn toàn do backbone. Notebook MobileNetV3 phân loại các crop của một ảnh theo batch và truyền ảnh đã đọc vào detector; EfficientNet-B0 phân loại từng crop và truyền đường dẫn ảnh vào detector. Thực nghiệm cũng chưa cung cấp nhiều lần đo, độ lệch chuẩn, warm-up và benchmark độ trễ chuẩn hóa. Không có runtime cùng giao thức cho hai detector trực tiếp, nên không lập bảng xếp hạng tốc độ của cả bốn phương án hoặc khẳng định tốc độ camera thời gian thực từ các số liệu này.

4.5 Hạn chế thực nghiệm và hướng cải thiện

Thứ nhất, kết quả hiện tại phản ánh một lần đánh giá của từng cấu hình trên một bộ dữ liệu và chưa có nhiều seed để ước lượng độ ổn định. Dữ liệu gồm các frame video; kiểm tra trùng byte giữa các tập chưa loại trừ sự tương đồng cao giữa frame liền kề hoặc cùng video nguồn. Khi có định danh video, cần chia dữ liệu theo nhóm video và đánh giá trên nguồn camera độc lập để kiểm chứng khả năng tổng quát hóa.

Thứ hai, tập test thiên về Violence, khác với camera thực tế thường có nhiều cảnh bình thường. Cần bổ sung cảnh phi bạo lực dễ gây nhầm như giao tiếp có cử chỉ mạnh, đám đông hoặc hoạt động thể thao, rồi lựa chọn ngưỡng dựa trên mục tiêu Recall và giới hạn số cảnh báo giả. Những tình huống này là hướng kiểm thử đề xuất, chưa được xác nhận là nguyên nhân lỗi của các ảnh test hiện tại.

Thứ ba, pipeline dùng DBSCAN với eps theo pixel cố định, có thể thay đổi hiệu quả khi độ phân giải hoặc khoảng cách camera thay đổi. Có thể chuẩn hóa khoảng cách gom nhóm theo kích thước ảnh, thử padding và ngưỡng confidence khác nhau trên validation. Đồng thời, cần thống nhất chính sách checkpoint và cách chạy batch trước khi kết luận về ưu thế kiến trúc hoặc tốc độ.

Thứ tư, các phương án hiện tại xử lý từng ảnh và chưa mô hình hóa chuyển động theo chuỗi. Hướng mở rộng là kết hợp theo dõi người, tổng hợp dự đoán trên nhiều frame liên tiếp hoặc thử mô hình có thông tin thời gian. Việc bổ sung cơ chế xác nhận cảnh báo cần được kiểm tra cả thời gian trễ và tỷ lệ bỏ sót để tránh làm giảm khả năng phát hiện sự kiện ngắn.

KẾT LUẬN

Kết quả đạt được

Đã xây dựng và đánh giá hệ thống phát hiện hành vi bạo lực trên bộ dữ liệu violence-bblcr v2 (tập test gồm 748 ảnh) qua 4 phương án:

YOLOv8n (Một giai đoạn): Đạt hiệu năng cân bằng nhất ở mức ảnh (Accuracy 85,83%, Precision 88,93%, Recall 93,24%, F1 lớp Violence 91,03%). Ở mức định vị, mô hình đạt mAP@0.50 = 84,64% và mAP@0.50:0.95 = 61,34% (vượt trội hơn EfficientDet-D0).

Pipeline 2 giai đoạn (YOLOv8n + MobileNetV3-Large / EfficientNet-B0): Đạt Recall cao (lần lượt 98,44% và 98,96%), bỏ sót ít bạo lực hơn nhưng phát sinh nhiều cảnh báo nhầm, dẫn đến F1 thấp hơn (88,47% và 87,78%).

Hạn chế của đề tài

Dữ liệu: Mới thử nghiệm trên 1 dataset; tỷ lệ lớp bạo lực ở tập test cao (577/748) chưa thực tế; chưa loại bỏ triệt để rủi ro rò rỉ các frame tương đồng từ cùng video nguồn giữa các tập.

Pipeline & Mô hình: Hai pipeline dùng tiêu chí chọn checkpoint chưa thống nhất (last.pth vs best_model.pth); dễ mất tín hiệu nếu phát hiện người hoặc crop lỗi; phụ thuộc vào tham số DBSCAN.

Đánh giá thời gian thực: Chưa chuẩn hóa benchmark đo độ trễ/thông lượng (chưa dùng chung thiết bị, batch size, warm-up) và thiếu thời gian chạy của detector một giai đoạn.

Hướng phát triển tương lai

Tối ưu dữ liệu: Chia tập dữ liệu theo video/nguồn camera; bổ sung các cảnh phi bạo lực dễ nhầm lẫn; thử nghiệm trên video/camera thực tế.

Cải tiến thuật toán: Thống nhất tiêu chí chọn checkpoint; tối ưu hệ thống ngưỡng phát hiện, khoảng cách DBSCAN và padding crop; bổ sung cơ chế theo dõi (tracking) hoặc tổng hợp dự đoán qua nhiều frame để giảm báo động giả.

TÀI LIỆU THAM KHẢO

[1] B. C. An, "https://bocongan.gov.vn/," [Trực tuyến]. Available: https://bocongan.gov.vn/bai-viet/so-lieu-ve-cong-tac-dau-tranh-phong-chong-toi-pham-nam-2025-1774611621. [Đã truy cập 8 10 2026].

[2] J. Redmon, S. Divvala, R. Girshick và A. Farhadi, "You Only Look Once: Unified, Real-Time Object Detection," trong *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Las Vegas, NV, USA · Year: 2016 · Pages: 779–788 · Publisher: IEEE, 2016.

[3] G. Jocher, A. Chaurasia và J. Qiu, "Ultralytics YOLOv8," 2023. [Trực tuyến]. Available: https://github.com/ultralytics/ultralytics.

[4] T.-Y. Lin, P. Dollár, R. Girshick, K. He, B. Hariharan và S. Belongie, "Feature Pyramid Networks for Object Detection," trong *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Honolulu, HI, USA · Year: 2017 · Pages: 2117–2125, 2017.

[5] S. Liu, L. Qi, H. Qin, J. Shi và J. Jia, "Path Aggregation Network for Instance Segmentation," trong *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Salt Lake City, UT, USA · Year: 2018 · Pages: 8759–8768, 2018.

[6] Z. Zheng, P. Wang, W. Liu, J. Li, R. Ye và D. Ren, "Distance-IoU Loss: Faster and Better Learning for Bounding Box Regression," trong *Proceedings of the AAAI Conference on Artificial Intelligence*, New York, NY, USA, 2020.

[7] X. Li, W. Wang, L. Wu, S. Chen, X. Hu, J. Li, J. Tang và J. Yang, "Generalized Focal Loss: Learning Qualified and Distributed Bounding Boxes for Dense Object Detection," trong *Advances in Neural Information Processing Systems (NeurIPS)*, 2020.

[8] C. Feng, Y. Zhong, Y. Gao, M. R. Scott và W. Huang, "TOOD: Task-aligned One-stage Object Detection," trong *IEEE/CVF International Conference on Computer Vision (ICCV)*, Montreal, QC, Canada, 2021.

[9] G. Jocher, "YOLOv5 by Ultralytics," Ultralytics, 2020. [Trực tuyến]. Available: https://github.com/ultralytics/yolov5.

[10] M. Tan, R. Pang và Q. V. Le, "EfficientDet: Scalable and Efficient Object Detection," trong *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, Seattle, WA, USA, 2020.

[11] M. Tan và Q. V. Le, " EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks," trong *Proceedings of the 36th International Conference on Machine Learning (ICML)*, Long Beach, CA, USA, 2019.

[12] T.-Y. Lin, P. Goyal, R. Girshick, K. He và P. Dollár, "Focal Loss for Dense Object Detection," trong *IEEE International Conference on Computer Vision (ICCV*, Venice, Italy, 2017.

[13] G. Ghiasi, T.-Y. Lin và Q. V. Le, "NAS-FPN: Learning Scalable Feature Pyramid Architecture for Object Detection," trong *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, Long Beach, CA, USA, 2019.

[14] J. Hu, L. Shen và G. Sun, "Squeeze-and-Excitation Networks," trong *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Salt Lake City, UT, USA, 2018.

[15] K. He, X. Zhang, S. Ren và J. Sun, "Deep Residual Learning for Image Recognition," trong *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Las Vegas, NV, USA, 2016.

[16] M. Tan, B. Chen, R. Pang, V. Vasudevan, M. Sandler, A. Howard và Q. V. Le, "MnasNet: Platform-Aware Neural Architecture Search for Mobile," trong

IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), Long Beach, CA, USA, 2019.

[17] S. J. Pan và Q. Yang, "A Survey on Transfer Learning," *IEEE Transactions on Knowledge and Data Engineering,* tập 22, số 10, p. 1345–1359, 2010.

[18] I. Goodfellow, Y. Bengio và A. Courville, Deep Learning, Cambridge, MA: MIT Press, 2016.

[19] A. Howard, M. Sandler, G. Chu, L.-C. Chen, B. Chen, M. Tan, W. Wang, Y. Zhu, R. Pang, V. Vasudevan, Q. V. Le và H. Adam, "Searching for MobileNetV3," trong *IEEE/CVF International Conference on Computer Vision (ICCV)*, Seoul, South Korea, 2019.

[20] A. G. Howard, M. Zhu, B. Chen, D. Kalenichenko, W. Wang, T. Weyand, M. Andreetto và H. Adam, "MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications," *arXiv preprint arXiv:1704.04861,* 2017.

[21] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov và L.-C. Chen, "MobileNetV2: Inverted Residuals and Linear Bottlenecks," trong *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Salt Lake City, UT, USA, 2018.

[22] D. M. W. Powers, "Evaluation: From Precision, Recall and F-Measure to ROC, Informedness, Markedness and Correlation," *Journal of Machine Learning Technologies,* tập 2, p. 1, 2011.

[23] M. Everingham, L. Van Gool, C. K. I. Williams, J. Winn và A. Zisserman, "The PASCAL Visual Object Classes (VOC) Challenge," *International Journal of Computer Vision,* tập 88, số 2, p. 303–338, 2010.

[24] T.-Y. Lin, M. Maire, S. Belongie, J. Hays, P. Perona, D. Ramanan, P. Dollár và C. L. Zitnick, "Microsoft COCO: Common Objects in Context," trong *European Conference on Computer Vision (ECCV)*, Zurich, Switzerland, 2014.

[25] B. Dwyer, J. Nelson, T. Hansen và e. al., “Roboflow,” 2024. [Trực tuyến]. Available: https://roboflow.com.